

01주차 · 임베딩의 언어: 표현과 공간

- 원본 연계: *Hands-On Large Language Models*, Chapter 2, “Tokens and Token Embeddings”
- 연결 슬라이드: [week01_embedding_foundations.md](#)
- 실습 노트북: [week01.ipynb](#)
- 권장 학습시간: 개념 45분 · 수학 30분 · 노트북 60분 · 토론과 정리 25분

이번 주에 답할 질문

임베딩을 처음 접하면 흔히 “비슷한 데이터를 가까운 점으로 바꾸는 기술”이라고 설명한다. 방향은 맞지만, 이 문장만으로는 어떤 점이 왜 가까워야 하는지 알 수 없다. 이번 주의 중심 질문은 다음과 같다.

“두 데이터가 가깝다”는 말은 어떤 관계를 보존하기로 약속했다는 뜻인가?

예를 들어 검색 시스템에서 “강아지”와 “반려견”은 의미가 비슷하다. 그러나 “강아지”와 “산책”은 뜻이 같지 않아도 검색 의도상 관련될 수 있다. “장학금 신청 마감일”이라는 질의에는 뜻이 비슷한 문서보다 정확한 날짜가 있는 문서가 유용하다. 따라서 임베딩의 품질은 벡터 그림이 예쁜지가 아니라 실제 과업의 관계를 보존하는지로 판단한다.

학습목표

학습을 마치면 다음을 할 수 있어야 한다.

1. 표현, 임베딩, 잠재공간과 표현학습의 차이를 설명한다.
2. 벡터와 임베딩 행렬의 모양을 데이터의 관측치·특징과 연결한다.
3. 내적, 벡터의 크기(L2 노름, norm), 코사인 유사도, 유클리드 거리를 계산한다.
4. L2 정규화 후 코사인 유사도와 유클리드 거리가 같은 순위를 만드는 이유를 유도한다.
5. 희소/밀집, 정적/문맥적, 단일/다중 벡터 표현을 구분한다.
6. 대조학습의 목적함수가 어떤 쌍을 가깝게 또는 멀게 만드는지 해석한다.
7. 토큰 ID, 토큰 임베딩, 문맥 은닉 상태, 문장 임베딩의 텐서 모양을 구분한다.
8. 임베딩을 과업 지표, 기준선, 오류 사례로 평가하는 실험을 설계한다.

1. 표현과 임베딩

1.1 표현

표현(representation)은 분석 대상 x 를 계산 가능한 형식으로 바꾼 결과다. 범주형 변수의 정수 코드, 문서의 단어 빈도 표, 이미지의 화소 배열도 모두 표현이다. 표현은 반드시 학습된 벡터일 필요가 없다.

예를 들어 전공을 다음과 같이 정수로 바꿀 수 있다.

전공	코드
컴퓨터학	0
경영학	1
관광학	2

이 코드는 계산 가능하지만 $2 - 0 = 2$ 라는 차이에 학문적 거리를 부여한 것은 아니다. 즉, 숫자로 바꾸었다는 사실만으로 의미 있는 기하 구조가 생기지는 않는다.

1.2 임베딩

임베딩(embedding)은 원래 공간의 대상을 유한 차원 벡터 공간으로 옮기면서 과업에 필요한 관계를 보존하려는 함수 또는 그 출력이다.

$$f_{\theta} : \mathcal{X} \rightarrow \mathbb{R}^d, \quad \mathbf{z} = f_{\theta}(x) \tag{3}$$

- $\mathcal{X}$: 단어, 문장, 이미지, 사용자, 그래프 노드와 같은 입력 공간
- d : 출력 벡터의 좌표 수, 즉 임베딩 차원
- θ : 데이터로부터 학습하거나 사람이 정한 함수의 매개변수
- $\mathbf{z}$: 입력 x 의 임베딩 벡터

중요한 점은 차원 d 가 “의미의 개수”와 같지 않다는 것이다. 학습된 좌표계는 회전해도 점 사이의 내적이나 거리가 유지될 수 있다. 따라서 한 좌표를 “관광성”, 다른 좌표를 “산업성”처럼 임의로 이름 붙이면 안 된다. 개별 좌표보다 이웃, 방향, 군집, 선형 부분공간을 분석하는 이유가 여기에 있다.

1.3 잠재공간과 표현학습

잠재공간(latent space)은 관측 자료에 직접 주어진 좌표가 아니라 모델이 학습 과정에서 구성한 내부 좌표계다. 표현학습(representation learning)은 과업에 유용한 좌표계를 데이터로부터 학습하는 과정이다.

모든 벡터가 임베딩으로 유용한 것은 아니다. 학생 이름을 임의의 난수 벡터로 바꾸어도 벡터는 만들어지지만, 학업 상담이나 과목 추천에 필요한 관계를 보존한다는 근거는 없다.

2. 임베딩을 분류하는 다섯 축

임베딩 모델을 비교할 때 “Transformer인가?”만 묻는 것은 충분하지 않다. 다음 분류축은 서로 독립적이므로 각각 확인해야 한다.

분류축	선택지	확인할 질문
값의 밀도	희소 표현 / 밀집 표현	대부분의 좌표가 0인가?
문맥 사용	정적 / 문맥적	같은 단어의 벡터가 문장에 따라 달라지는가?
출력 단위	토큰 / 문장·문서 / 객체	한 벡터가 무엇을 대표하는가?
객체당 벡터 수	단일 벡터 / 다중 벡터	객체마다 하나인가, 토큰·패치마다 있는가?
입력 양식	단일 / 멀티모달	텍스트와 이미지 등을 같은 공간에서 비교하는가?

예를 들어 TF-IDF 문서 벡터는 희소하고 문서마다 하나다. Word2Vec은 단어마다 하나의 정적 밀집 벡터를 갖는다. BERT의 은닉 상태는 문맥적이며 토큰마다 하나씩 나온다. ColBERT는 문서의 여러 토큰 벡터를 유지하는 문맥적 다중 벡터 검색기다.

이 분류는 2주차 희소 표현, 3주차 정적 단어 임베딩, 4주차 문맥 임베딩, 5주차 문장 임베딩으로 이어지는 전체 강의의 지도다.

3. 벡터와 임베딩 행렬

문서 n 개를 d 차원으로 임베딩하면 벡터를 행 방향으로 쌓아 행렬을 만든다.

$$E = \begin{bmatrix} \mathbf{e}_1^\top \\ \vdots \\ \mathbf{e}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times d} \tag{4}$$

- 한 행 $\mathbf{e}_i \in \mathbb{R}^d$: 문서·사용자·상품 하나의 표현
- 한 열: 모델이 학습한 좌표축 하나
- 행렬 E : 여러 객체를 일괄 검색·분류·군집화하기 위한 입력

예를 들어 문서 1,000개를 384차원으로 표현하면 E 의 모양은 $[1000, 384]$ 다. 질의 20개의 행렬 $Q \in \mathbb{R}^{20 \times 384}$ 와 내적하면 $QE^\top \in \mathbb{R}^{20 \times 1000}$ 이 되어 모든 질의-문서 점수를 한 번에 얻는다. 텐서 모양을 읽을 수 있어야 코드가 무엇을 비교하는지 검증할 수 있다.

4. 벡터의 기하

4.1 벡터의 크기와 내적

벡터 $\mathbf{x} = (x_1, \dots, x_d)$ 의 L2 노름은 원점에서의 길이이다.

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^d x_i^2} \quad (5)$$

두 벡터의 내적은 대응 성분의 곱을 더한 값이다.

$$\mathbf{x}^\top \mathbf{y} = \sum_{i=1}^d x_i y_i \quad (6)$$

기하학적으로는 다음 관계가 성립한다.

$$\mathbf{x}^\top \mathbf{y} = \|\mathbf{x}\|_2 \|\mathbf{y}\|_2 \cos \theta \quad (7)$$

따라서 내적에는 방향의 일치 정도뿐 아니라 두 벡터의 크기도 함께 들어간다.

4.2 유클리드 거리와 코사인 유사도

유클리드 거리는 두 점을 잇는 직선거리다.

$$d_2(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2 \quad (8)$$

코사인 유사도는 두 벡터가 이루는 각도의 코사인이다.

$$\cos(\mathbf{x}, \mathbf{y}) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\|_2 \|\mathbf{y}\|_2} \quad (9)$$

코사인 유사도는 일반적으로 $([-1, 1])$ 범위이며 클수록 방향이 비슷하다. 유클리드 거리는 0 이상이며 작을수록 가깝다. 라이브러리가 “코사인 거리”로 $(1 - \operatorname{cos})$ 을 반환하는지 반드시 확인해야 한다.

4.3 손계산 예제

$\mathbf{x} = (3, 4)$, $\mathbf{y} = (4, 3)$ 이라 하자.

$$\|\mathbf{x}\|_2 = \|\mathbf{y}\|_2 = 5, \quad \mathbf{x}^\top \mathbf{y} = 3 \times 4 + 4 \times 3 = 24 \quad (10)$$

$$\cos(\mathbf{x}, \mathbf{y}) = \frac{24}{25} = 0.96 \quad (11)$$

$$d_2(\mathbf{x}, \mathbf{y}) = \sqrt{(3 - 4)^2 + (4 - 3)^2} = \sqrt{2} \approx 1.414 \quad (12)$$

방향은 매우 비슷하지만 두 점은 동일하지 않다. 이 결과를 노트북의 `cosine` 과 `euclidean` 함수 출력과 비교한다.

4.4 L2 정규화 후 지표가 연결되는 이유

$\hat{\mathbf{x}} = \mathbf{x} / \|\mathbf{x}\|_2$, $\hat{\mathbf{y}} = \mathbf{y} / \|\mathbf{y}\|_2$ 라 두면 두 벡터의 크기는 1이다.

$$\begin{aligned} \|\hat{\mathbf{x}} - \hat{\mathbf{y}}\|_2^2 &= (\hat{\mathbf{x}} - \hat{\mathbf{y}})^\top (\hat{\mathbf{x}} - \hat{\mathbf{y}}) \\ &= \|\hat{\mathbf{x}}\|_2^2 + \|\hat{\mathbf{y}}\|_2^2 - 2\hat{\mathbf{x}}^\top \hat{\mathbf{y}} \\ &= 2 - 2\cos(\mathbf{x}, \mathbf{y}). \end{aligned} \quad (13)$$

따라서 단위 벡터에서는 코사인을 크게 만드는 순서와 유클리드 거리를 작게 만드는 순서가 같다. 정규화하지 않으면 벡터 크기가 내적과 거리에 영향을 주므로 같은 결론을 보장할 수 없다. 어떤 모델은 크기에 빈도나 확신과 관련된 정보를 담을 수 있으므로 정규화 여부도 실험 조건이다.

5. “가까움”을 과업으로 정의하기

가까움은 자연법칙이 아니라 데이터, 학습목표, 점수 함수가 만든 결과다.

- 의미 유사성: “강아지”–“반려견”처럼 뜻이 유사한 관계
- 관련성: “강아지”–“산책”처럼 함께 필요하지만 뜻은 다른 관계

- 과업 적합성: 질문과 그 질문에 답하는 문서의 관계
- 범주 분리: 같은 범주를 모으기보다 결정 경계를 만들기 쉬운 관계

운영적 정의(operational definition)는 “좋다” 같은 추상 개념을 데이터와 측정 규칙으로 바꾸는 것이다. 예를 들어 다음 문장은 측정 불가능하다.

“우리 임베딩은 한국어 의미를 잘 이해한다.”

다음과 같이 바꾸면 검증할 수 있다.

“학사 규정 질의 200개에서 TF-IDF 기준선보다 상위 5개 재현율을 높이고, 학과별 성능 차이를 5%p 이내로 유지한다.”

임베딩 계약서를 작성할 때는 입력, 보존 관계, 점수 함수, 정답 레이블, 허용 가능한 오류와 운영 비용을 함께 명시한다.

6. 고차원 공간에서 생기는 문제

차원이 커지면 표현력이 자동으로 좋아지는 것은 아니다.

1. 공간의 부피가 빠르게 증가해 같은 수의 자료가 더 희박해진다.
2. 최근접 이웃과 먼 이웃의 거리 차이가 상대적으로 작아지는 거리 집중이 나타날 수 있다.
3. 일부 점이 여러 질의의 이웃으로 반복되는 허브니스(hubness)가 생길 수 있다.
4. 2차원 축소 그림은 원래 공간의 국소 구조와 전역 구조를 동시에 완벽히 보존하지 못한다.

따라서 “768차원이므로 384차원보다 의미가 풍부하다”는 주장은 충분하지 않다. 동일한 데이터, 학습목표, 지표, 저장 공간과 지연시간 조건에서 비교해야 한다. PCA·t-SNE·UMAP 그림은 탐색 도구이지 성능의 최종 증거가 아니다.

7. 임베딩은 어떻게 학습되는가

일반적인 흐름은 입력 x , 인코더 f_θ , 벡터 z , 손실함수 $\mathcal{L}$ 로 쓸 수 있다.

$$x \longrightarrow f_\theta(x) = z \longrightarrow \mathcal{L}(z) \tag{14}$$

학습 신호	가까워지게 하는 예	주의점
분포 기반	비슷한 문맥의 단어	말뭉치 편향을 함께 학습
지도학습	같은 정답 범주의 예	레이블 정의에 종속
대조학습	관련 쌍	비관련 표본의 품질이 중요
생성 사전학습	토큰 예측에 유용한 상태	문장 간 거리 최적화와 같지 않음

7.1 대조학습의 최소 수식

질의 q_i , 관련 문서 d_i^+ , 후보 문서 d_j 가 있을 때 한 가지 손실은 다음과 같다.

$$\mathcal{L}_i = -\log \frac{\exp(s(q_i, d_i^+)/\tau)}{\sum_j \exp(s(q_i, d_j)/\tau)} \quad (15)$$

- s : 내적 또는 코사인 점수
- τ : 점수 분포의 날카로움을 조절하는 온도(temperature)
- 배치 내 비관련 표본: 같은 배치의 다른 문서를 비관련 후보로 재사용하는 방식

관련 문서 점수가 2, 비관련 문서 점수가 0이고 $\tau = 1$ 이면 관련 문서의 확률은 $e^2/(e^2 + e^0) \approx 0.881$, 손실은 약 0.127이다. 관련 문서 점수가 낮아지면 손실이 커지고, 경사하강법은 관련 쌍의 점수를 높이도록 작동한다. 실제로 관련 있는 문서를 비관련 표본으로 잘못 넣으면 모델에 모순된 학습 신호를 준다.

8. Hands-On LLM 2장을 읽는 방법

교재는 모델과 토큰화기를 따로 불러온 뒤 다음 표현 계층을 보여준다.

문자열 → 토큰 ID → 토큰 임베딩 → 문맥 은닉 상태 → 풀링된 텍스트 벡터

이 단계들은 모두 관습적으로 “임베딩”이라 불리지만 서로 다른 객체다.

객체	대표 모양	의미
<code>input_ids</code>	<code>[B, T]</code>	배치별 토큰 정수 ID
입력 임베딩	<code>[B, T, H]</code>	문맥화 전 토큰 벡터
<code>last_hidden_state</code>	<code>[B, T, H]</code>	문맥에 따라 달라진 토큰 벡터
풀링된 출력	<code>[B, H]</code>	문장·문서당 단일 벡터
유사도 행렬	<code>[Q, D]</code>	모든 질의-문서 쌍의 점수

B 는 배치 크기, T 는 토큰 길이, H 는 은닉 차원이다. 패딩을 포함해 단순 평균하면 짧은 문장이 더 크게 왜곡될 수 있다. 어텐션 마스크가 1인 실제 토큰만 더한 뒤 실제 토큰 수로 나누어야 한다. 또한 생성 언어 모델의 은닉 상태를 무조건 평균한다고 좋은 검색 벡터가 되는 것은 아니다. 문장 유사도·검색 목표로 학습된 모델인지 확인한다.

교재의 노래 추천 예제도 “최근접 이웃 출력”으로 끝내지 않는다.

1. 대상은 곡 ID인가, 가사인가, 곡 설명인가?
2. Word2Vec의 문맥은 같은 재생목록 안에서 함께 등장한 곡인가?
3. 코사인 이웃이 사용자의 선호와 일치한다는 정답은 어떻게 수집하는가?
4. 인기 편향, 다양성, 신규성과 시간 변화는 어떻게 평가하는가?

이 질문을 통해 한 줄의 `most_similar` 를 평가 가능한 추천 실험으로 바꿀 수 있다.

9. 실패 사례를 읽는 법

질의가 “장학금 신청 마감일은?”이라고 하자.

후보 문서	표면 의미 유사성	정답 적합성
장학금 신청 절차와 제출 서류	높음	낮음
2026학년도 2학기 신청은 8월 28일까지	중간	높음
등록금 납부 마감일 안내	중간	낮음

임베딩은 날짜, 부정, 학기 버전, 권한 같은 정밀 제약을 놓칠 수 있다. 이 문제를 “모델이 멍청하다”라고만 기록하면 개선 방향을 찾기 어렵다. 희소·밀집 혼합 검색, 메타데이터 필터, 재순위화, 최신성 필터 중 어느 구성요소가 어떤 오류를 줄이는지 8주차에서 검증한다.

10. 논문 읽기: Matryoshka Representation Learning

Matryoshka Representation Learning(MRL)은 긴 임베딩 벡터의 앞부분도 독립적으로 유용하도록 여러 접두 길이
에 동시에 학습 신호를 주는 방법이다.

$$\mathcal{L} = \sum_{m \in \mathcal{M}} \lambda_m \mathcal{L}_m(\mathbf{z}_{1:m}) \quad (16)$$

예를 들어 768차원 벡터를 학습하면서 64, 128, 256, 768차원 접두 벡터에도 각각 분류나 검색 손실을 준다. 서비스는
저장공간과 지연시간에 따라 사용할 차원을 선택할 수 있다. 짧은 벡터로 후보를 넓게 찾고 긴 벡터로 다시 비교하는 단계
적 검색도 가능하다. 이는 학습 후 벡터를 임의로 자르는 것과 다르다.




그림 1. 하나의 표현 안에 여러 차원의 유용한 접두 표현을 중첩하고,
낮은 비용의 짧은 벡터에서 높은 비용의 긴 벡터로 단계적으로 분류 검색하는 개념도. 출처: Kusupati et al. (2022),
“Matryoshka Representation Learning,” Figure 1, [원 논문](#).

그림은 왼쪽에서 오른쪽으로 읽는다. 학습 단계에서는 서로 다른 길이의 접두 벡터가 모두 손실함수에 연결되어 있다. 추
론 단계에서는 요구 정확도와 계산 예산에 따라 접두 길이를 선택한다. 그림이 주장하는 핵심은 “긴 벡터가 항상 낫다”가
아니라 하나의 학습된 표현으로 정확도-비용 상충 관계를 조절할 수 있다는 점이다.

슬라이드가 소개하는 최근 방향에는 다중 벡터와 전 양식(omnimodal) 임베딩도 있다. 다만 2026년 사전 공개 논문인 [Gemini Embedding 2](#)와 [jina-embeddings-v5-omni](#)의 결과는 출판 버전, 평가 데이터, 사용 언어, 비용과 라이선스를 확인한 뒤 해석해야 한다. 새 모델 이름 자체보다 “어떤 관계를 어떤 비용으로 보존했는가”를 읽는 습관이 중요하다.

11. 노트북 실습 안내

[week01.ipynb](#) 은 외부 모델 없이 NumPy로 실행된다. 다음 순서로 학습하면 수식과 코드의 연결을 확인하기 쉽다.

실행 점검 1 · 준비 셀

첫 번째 코드 셀을 실행해 난수 시드를 42로 고정하고 `cosine` 함수의 분모를 확인한다. 영벡터가 들어오면 분모가 0 이므로 함수가 0을 반환한다. 수학적으로 영벡터의 코사인은 정의되지 않으므로, 서비스에서는 오류·결측 처리 규칙을 따로 정해야 한다.

실행 점검 2 · 거리표

`vectors` 사전에는 “해양 관광”, “섬 여행”, “배터리 공정”, “조선 제조”의 2차원 벡터가 있다. 실행 전에 가장 가까운 두 쌍을 코사인과 유클리드 거리별로 예측한다. 출력 표에서 두 지표의 순위가 같은지 확인하고, 다르면 벡터 크기를 비교한다.

실행 점검 3 · 산점도

산점도의 축 이름 “차원 1”, “차원 2”는 실제 의미 이름이 아니다. 점의 상대 위치만 읽고, 축 의미를 사후에 만들어내지 않는다. 모든 벡터를 회전시켜도 거리와 코사인 관계가 유지되는지 생각해 본다.

실행 점검 4 · 학생 확장 활동

새 항목 세 개와 벡터를 추가하되 먼저 원하는 관계를 문장으로 적는다. 그 다음 좌표를 정하고 두 지표의 결과가 그 관계를 보존하는지 검사한다. 성공 사례 하나와 실패 사례 하나를 수치로 설명한다.

학습 기록

노트북 마지막 셀에는 결과, 근거 수치, 예상과 달랐던 점, 생성형 AI의 프롬프트와 채택·거부·검증 내역을 자신의 말로 기록한다. 생성형 AI가 제시한 해석도 직접 수식이나 실행 결과로 검증해야 한다.

12. 흔한 오해와 교정

1. “차원 하나가 의미 하나다.”

학습된 의미는 여러 좌표에 분산될 수 있고, 좌표계 회전에도 관계가 유지된다.

2. “코사인 0.9면 반드시 관련 문서다.”

점수의 의미는 모델·자료 분포·과업에 종속되며 임곗값은 개발 데이터에서 정한다.

3. “차원이 크면 항상 좋다.”

저장공간·속도·과적합·거리 집중과 실제 과업 성능을 함께 비교해야 한다.

4. “2차원 그림에서 군집이 보이면 모델이 검증되었다.”

차원 축소가 구조를 왜곡할 수 있으므로 정량 지표와 원공간의 이웃을 확인한다.

5. “언어 모델 은닉 상태를 평균하면 문장 임베딩이다.”

벡터는 만들어지지만 문장 유사도나 검색에 적합하도록 학습되었다는 보장은 없다.

6. “최근접 이웃이 그럴듯하면 배포해도 된다.”

기준선, 충분한 정답 자료, 부분집합별 오류, 지연시간과 비용 평가가 필요하다.

13. 핵심 정리

- 임베딩은 원래 대상의 과업 관련 관계를 벡터 공간에 보존하려는 함수와 출력이다.
- 가까움의 의미는 데이터, 학습목표, 점수 함수와 평가 레이블이 함께 결정한다.
- 내적은 방향과 크기를 함께 사용하고, 코사인은 방향을 비교하며, 유클리드 거리는 점 사이 길이를 잴다.
- L2 정규화된 벡터에서는 코사인 최대화와 유클리드 거리 최소화가 같은 순위를 만든다.
- 텐서 모양, 패딩 마스크, 풀링, 잘림과 정규화 규칙을 알아야 코드 결과를 해석할 수 있다.
- 임베딩은 이웃 몇 개가 아니라 과업 지표, 기준선, 오류 분석과 운영 비용으로 평가한다.
- 현대 임베딩은 가변 차원, 다중 벡터, 멀티모달 표현으로 확장되고 있다.

14. 복습문제

1. 범주를 정수로 바꾸는 것과 임베딩의 차이를 예를 들어 설명하라.
2. 임베딩 차원 하나를 독립적인 의미로 해석하기 어려운 이유를 좌표계 회전과 연결하라.
3. $\mathbf{a} = (1, 2)$, $\mathbf{b} = (2, 1)$ 의 L2 노름, 내적, 코사인, 유클리드 거리를 계산하라.

4. L2 정규화된 벡터에서 코사인 순위와 유클리드 거리 순위가 같은 이유를 유도하라.
5. 의미 유사성과 검색 관련성이 다른 사례를 하나씩 제시하라.
6. $[B, T, H]$ 와 $[B, H]$ 가 각각 무엇을 표현하는지 설명하라.
7. 패딩 토큰을 포함한 평균 풀링이 짧은 문장을 더 왜곡할 수 있는 이유는 무엇인가?
8. 대조학습에서 실제 관련 문서를 비관련 표본으로 사용하면 어떤 학습 신호가 생기는가?
9. MRL과 학습 후 단순 벡터 잘림의 차이는 무엇인가?
10. 학사 정보 검색용 임베딩의 운영적 정의를 데이터·지표·위험을 포함해 한 문장으로 작성하라.

15. 참고문헌

1. Alammr, J., & Grootendorst, M. (2024). *Hands-On Large Language Models*, Chapter 2. [공개 실습 저장소](#)
2. Bengio, Y., Courville, A., & Vincent, P. (2013). "Representation Learning: A Review and New Perspectives." [IEEE](#)
3. Mikolov, T. et al. (2013). "Efficient Estimation of Word Representations in Vector Space." [arXiv](#)
4. Vaswani, A. et al. (2017). "Attention Is All You Need." [arXiv](#)
5. Reimers, N., & Gurevych, I. (2019). "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks." [EMNLP](#)
6. Wang, T. et al. (2020). "Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere." [ICML](#)
7. Kusupati, A. et al. (2022). "Matryoshka Representation Learning." [NeurIPS](#)
8. Radovanović, M., Nanopoulos, A., & Ivanović, M. (2010). "Hubs in Space: Popular Nearest Neighbors in High-Dimensional Data." [JMLR](#)
9. Lee, S. et al. (2025). "Massive Multilingual Text Embedding Benchmark." [arXiv](#)