

06주차 · 임베딩 기반 분류·군집·시각화

- 연계 슬라이드: [06주차 슬라이드](#)
- 실습 Notebook: [week06.ipynb](#)
- 교재 연계: *Hands-On Large Language Models* 4장과 5장
- 권장 학습 순서: 분석 단위 정의 → 분류 → 군집 → 차원 축소 → BERTopic → Notebook

1. 임베딩 생성은 분석의 시작이다

텍스트를 임베딩으로 바꾸면 각 문서가 수치 벡터가 된다. 이후에는 로지스틱 회귀, k-최근접 이웃, k-means, 차원 축소 같은 데이터 과학 방법을 적용할 수 있다. 그러나 점들이 보기 좋게 나뉜 그림만으로 “의미 구조를 발견했다”고 결론 내려서는 안 된다.

임베딩 기반 분석은 다음 연결 전체를 검증해야 한다.

분석 단위 → 임베딩 모델 → 거리·정규화 → 알고리즘 → 평가 지표 → 오류 분석

어느 한 단계가 바뀌면 결론도 바뀔 수 있다. 예를 들어 같은 문서라도 문장 단위와 문단 단위의 벡터 구조가 다르며, 코사인 거리와 유클리드 거리가 다른 이웃을 만들 수 있다. UMAP 그림의 군집이 원래 고차원 공간에서도 유지되는지도 별도로 확인해야 한다.

2. 학습목표

학습을 마치면 다음을 할 수 있어야 한다.

- 임베딩 행렬과 정답 범주의 모양, 분석 단위를 명시한다.
- 같은 문서의 청크가 데이터 분할에 섞일 때 생기는 그룹 누수를 설명한다.
- 선형 판독 모델, k-NN, 무예시 범주 대표 벡터 분류를 비교한다.
- 정확도, 매크로 F1, 혼동행렬을 오류 비용에 맞게 해석한다.
- k-means 목적함수와 군집 중심 갱신을 작은 예제로 계산한다.
- 실루엣 계수와 외부 군집 지표가 답하는 질문을 구분한다.

- PCA, t-SNE, UMAP의 보존 대상과 시각화 한계를 설명한다.
- BERTopic의 임베딩-UMAP-HDBSCAN-c-TF-IDF 파이프라인을 설명한다.
- Notebook의 미니 실험을 실제 평가 절차로 확장할 때 필요한 수정을 제안한다.

3. 분석 단위와 행렬부터 고정한다

문서 n 개를 d 차원 벡터로 표현하면 임베딩 행렬은

$$E = \begin{bmatrix} \mathbf{z}_1^\top \\ \vdots \\ \mathbf{z}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times d} \quad (1)$$

이다. 분류 정답은 $y \in \{1, \dots, C\}^n$ 으로 둘 수 있다. 행 하나가 문장인지, 문단인지, 문서인지, 사용자 기록인지 먼저 써야 한다. 분석 단위가 불명확하면 모델의 오류 단위도 평가할 수 없다.

데이터를 만들 때 확인할 사항은 다음과 같다.

- 빈 문자열, 중복, 깨진 문서, 최대 길이 초과 문서를 어떻게 처리했는가?
- 임베딩 모델명·버전·접두문·풀링·정규화가 기록되었는가?
- 같은 원문의 여러 청크가 서로 다른 분할에 들어갔는가?
- 정답 범주가 임베딩 모델의 사전학습·미세 조정 데이터에 포함되었을 가능성이 있는가?
- 학습·개발·최종 평가 데이터를 문서·주제·시간 중 어떤 기준으로 나눴는가?

같은 문서에서 나온 두 청크는 어휘와 문맥이 매우 비슷하다. 청크를 무작위로 나누면 최종 평가 청크의 거의 동일한 이웃이 학습 데이터에 존재해 성능이 부풀려질 수 있다. 이를 막으려면 원문 ID를 그룹으로 묶어 한 그룹 전체가 하나의 분할에만 들어가게 한다.

4. 임베딩을 특징으로 쓰는 선형 판독 모델

선형 판독 모델(linear probe)은 임베딩을 고정하고 단순 선형 분류기만 학습한다.

$$P(y = c \mid \mathbf{z}) = \text{softmax}(W\mathbf{z} + \mathbf{b})_c \quad (2)$$

$W \in \mathbb{R}^{C \times d}$ 의 각 행은 한 범주의 결정 방향을 나타낸다. 선형 판독 모델의 성능이 높다면 해당 정답 정보가 임베딩 공간에서 선형적으로 읽히기 쉽다는 뜻이다. 이것이 표현에 그 정보만 인코딩되었다거나 인과적으로 사용된다는 뜻은 아니다.

두 범주라면 로지스틱 함수로 단순화할 수 있다.

$$P(y = 1 \mid \mathbf{z}) = \sigma(\mathbf{w}^\top \mathbf{z} + b) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{z} + b)}} \quad (3)$$

예를 들어 $\mathbf{z} = [2, 1]$, $\mathbf{w} = [1, -0.5]$, $b = 0$ 이면 로짓은 1.5이고 확률은 약 0.818이다. 임계값이 0.5라면 범주 1로 분류하지만, 임계값은 오류 비용에 따라 달라질 수 있다.

고차원 임베딩과 작은 데이터에서는 과적합을 막는 규제가 중요하다. 범주 불균형이 있으면

`class_weight` 또는 재표본화를 검토하되, 개발 데이터에서 선택하고 최종 평가에서는 고정한다.

5. 왜 단순 기준선이 필요한가

임베딩 + 로지스틱 회귀가 좋아 보여도 TF-IDF + 같은 분류기보다 나은지 확인해야 한다.

도메인 범주가 특정 키워드로 잘 구분되면 희소 기준선이 더 빠르고 정확할 수 있다. 반대로 동의어와 문맥이 중요하다면 임베딩의 이점이 나타날 수 있다.

공정한 비교에서는 데이터 분할, 분류기, 지표, 하이퍼파라미터 선택 예산을 맞춘다. “최신 모델”만 더 많이 조정하면 뒤 단순 기준선의 기본 설정과 비교하면 방법이 아니라 실험 노력의 차이를 측정한다.

6. k-최근접 이웃 분류

새 벡터 $\mathbf{z}$ 의 가까운 학습 이웃 집합을 $N_k(\mathbf{z})$ 라 하자. 다수결 예측은

$$\hat{y} = \arg \max_c \sum_{i \in N_k(\mathbf{z})} \mathbb{1}[y_i = c] \quad (4)$$

이다. 유사도로 가중치하면

$$\hat{y} = \arg \max_c \sum_{i \in N_k(\mathbf{z})} s(\mathbf{z}, \mathbf{z}_i) \mathbb{1}[y_i = c] \quad (5)$$

가 된다. k-NN은 복잡한 결정 경계를 직접 학습하지 않아 임베딩의 국소 구조를 살펴보기 좋다. 하지만 k , 거리, 정규화, 범주별 표본 밀도에 민감하다. 학습 데이터가 크면 정확 탐색 대신 근사 최근접 이웃 탐색 색인이 필요할 수 있다.

오류 분석에서는 예측 범주만 보지 말고 상위 이웃의 원문과 거리를 함께 본다. 잘못된 라벨, 같은 원문의 중복, 길이·문체에 따른 이웃 형성이 드러날 수 있다.

7. 무예시 범주 대표 벡터 분류

레이블 데이터가 없을 때 각 범주의 설명문을 임베딩해 범주 대표 벡터(prototype)로 사용할 수 있다.

$$\mathbf{p}_c = f_\theta(\text{“이 문서는 범주 } c \text{에 관한 글”}) \tag{6}$$

$$\hat{y} = \arg \max_c \cos(f_\theta(x), \mathbf{p}_c) \tag{7}$$

범주 이름 하나만 쓰면 다의성에 민감하다. “창업” 대신 정의문과 실제 예시를 넣어 여러 대표 벡터를 평균할 수 있다. 하지만 가장 높은 점수를 무조건 선택하면 모든 입력을 기존 범주 중 하나로 억지 분류한다. 최대 점수가 개발 데이터에서 정한 임계값보다 낮을 때 “기타”로 보내는 규칙이 필요하다.

평가에서는 레이블 이름, 정의문, 세 개 예시의 세 조건을 비교해 프롬프트 민감도를 보고한다.

8. 분류 평가와 혼동행렬

지표	정의	주요 해석
정확도	전체 예측 중 정답 비율	범주가 균형일 때 전체 성능
정밀도	예측 양성 중 실제 양성 비율	잘못된 관련 판정 비용
재현율	실제 양성 중 찾아낸 비율	놓친 양성의 비용
매크로 F1	범주별 F1의 단순 평균	희귀 범주에도 같은 가중치
혼동행렬	정답-예측 범주의 교차 빈도	어떤 범주 쌍이 혼동되는가

불균형 데이터에서 모든 사례를 다수 범주로 예측해도 정확도가 높을 수 있다. 매크로 F1과 범주별 재현율을 함께 보고, 혼동행렬의 대표 오류 원문을 읽는다. 임계값과 모델 선택은 개발 데이터에서 끝내고, 최종 평가 데이터는 마지막 한 번의 성능 측정에만 사용한다.

9. 군집화는 정답 없는 분할 가설이다

분류는 정답 범주로 결정 경계를 학습하지만, 군집화는 벡터와 거리만으로 집단을 만든다. 군집은 데이터에 유일하게 존재하는 “진짜 묶음”이 아니라 알고리즘·거리·해상도가 만든 분할일 수 있다.

같은 정책 문서도 주제에 따라 창업·복지·관광으로 묶일 수 있고, 지역에 따라 목포·무안·신안으로 묶일 수 있다. 어떤 분할이 유용한지는 분석 목적과 사람 평가로 결정한다.

10. k-means 목적함수와 손계산

k-means는 군집 내 제곱 유클리드 거리의 합을 최소화한다.

$$J = \sum_{k=1}^K \sum_{\mathbf{z}_i \in C_k} \|\mathbf{z}_i - \boldsymbol{\mu}_k\|_2^2 \tag{8}$$

점 $[0, 0], [0, 2], [8, 8], [10, 8]$ 을 두 군집으로 나누면 자연스러운 군집 중심은 $[0, 1]$ 과 $[9, 8]$ 이다. 각 점의 중심까지 제곱거리는 모두 1이므로 $J = 4$ 다. 만약 $[0, 2]$ 를 둘째 군집에 넣으면 중심과 목적함수가 바뀌며 비용이 커진다.

k-means는 다음 과정을 반복한다.

1. 각 점을 가장 가까운 중심에 할당한다.
2. 각 군집의 평균으로 중심을 갱신한다.
3. 할당이 안정되거나 반복 한도에 도달할 때까지 반복한다.

K 를 미리 정해야 하고, 비슷한 크기·밀도의 불룩한 군집에 잘 맞는다. 초기값에 따라 지역 최적해가 달라지므로 k-means++와 여러 난수 시드를 사용한다. L2 정규화 벡터의 코사인 구조에는 중심도 정규화하는 구면 k-means가 더 자연스러울 수 있다.

11. 계층 군집과 밀도 기반 군집

계층 군집(hierarchical clustering)은 가까운 군집을 차례로 합치거나 큰 군집을 나눠 덴드로그램을 만든다. 단일·완전·평균·Ward 연결법은 군집 사이 거리를 다르게 정의하므로 결과가 달라진다.

DBSCAN은 반경 ϵ 안에 최소 표본 수가 있는 밀집 영역을 확장하고 희박한 점을 잡음으로 남긴다. 군집 수를 미리 정하지 않고 비구형 군집을 찾을 수 있지만 밀도가 서로 다른 데이터에서는 하나의 ϵ 선택이 어렵다.

HDBSCAN은 여러 밀도 수준에서 안정적인 군집을 찾고 잡음 점을 분리한다. BERTopic은 기본적으로 UMAP으로 축소된 공간에 HDBSCAN을 적용하므로, 최종 주제는 두 알고리즘의 설정에 함께 종속된다.

12. 군집 품질을 한 숫자로 끝내지 않기

실루엣 계수(silhouette score)는 점 i 가 같은 군집에 얼마나 응집되고 다른 군집과 얼마나 분리되는지 측정한다. $a(i)$ 를 같은 군집 점들과의 평균 거리, $b(i)$ 를 가장 가까운 다른 군집과의 평균 거리라고 하면

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (9)$$

이며 범위는 $[-1, 1]$ 이다. 1에 가까우면 잘 분리되고, 0 부근이면 경계에 있으며, 음수이면 다른 군집에 더 가까울 수 있다.

내부 지표는 정답 없이 공간의 응집·분리를 측정한다. ARI, NMI, V-measure 같은 외부 지표는 정답 범주와 군집의 일치도를 측정한다. 둘은 다른 질문에 답한다. 실루엣 계수가 높아도 길이, 언어, 문체처럼 분석 목적과 무관한 속성으로 분리되었을 수 있다.

여러 난수 시드와 부트스트랩 표본에서 군집 겹침률을 측정하고, 각 군집의 대표·경계·이상 문서를 사람이 읽어야 한다.

13. PCA: 분산이 큰 선형 방향 찾기

평균을 뺀 행렬을 X 라 할 때 주성분 분석(principal component analysis, PCA)의 첫 방향은

$$\mathbf{w}_1 = \arg \max_{\|\mathbf{w}\|_2=1} \text{Var}(X\mathbf{w}) \quad (10)$$

이다. 이는 공분산 행렬 $X^\top X / (n - 1)$ 의 가장 큰 고윳값에 대응하는 고유벡터이며, 이후 방향은 앞 방향과 직교하면서 남은 분산을 최대화한다. 특이값 분해로도 안정적으로 계산할 수 있다.

PCA는 선형이고 빠르며 새 데이터에 같은 변환을 적용할 수 있다. 설명 분산 비율은 선택한 축이 전체 분산 중 얼마를 보존하는지 보여준다. 2차원 설명 분산이 낮다면 그림은 원래 구조의 작은 일부다.

희소 TF-IDF 행렬은 평균을 빼면 밀집 행렬이 되므로, Notebook은 중심화를 생략한 TruncatedSVD를 사용한다. 이를 일반적인 PCA와 완전히 같은 것으로 부르지 않아야 한다.

14. t-SNE와 UMAP

t-SNE는 고차원에서 가까운 점 쌍의 확률을 저차원에서도 비슷하게 만들도록 최적화한다. 국소 이웃을 잘 드러내지만 군집 사이 빈 공간, 면적, 전역 거리를 직접 해석하면 안 된다. perplexity와 난수 시드에 따라 그림이 달라진다.

UMAP은 국소 이웃 그래프를 만들고 저차원에서 그 퍼지 위상 구조를 근사한다. `n_neighbors` 는 국소와 전역 구조의 균형, `min_dist` 는 점들이 뭉치는 정도에 영향을 준다. UMAP도 전역 거리를 완전히 보존하지 않으며 거리 함수와 난수 시드에 민감하다.

시각화는 가설 생성 도구다. 다음을 원래 d 차원 공간에서 다시 확인한다.

- 상위 k 개 이웃 겹침률
- 원공간과 2차원 거리의 상관
- 분류 매크로 F1
- 군집 실루엣 계수와 안정성
- 대표 문서의 실제 의미

15. BERTopic 파이프라인

BERTopic의 기본 흐름은 다음과 같다.

문서 임베딩 → UMAP 차원 축소 → HDBSCAN 군집 → c-TF-IDF 대표어 → 주제 이름

임베딩 모델은 의미 공간을, UMAP은 군집화에 사용할 저차원 이웃 구조를, HDBSCAN은 밀도 기반 군집을 만든다. c-TF-IDF(class-based TF-IDF)는 한 군집의 모든 문서를 하나의 “범주 문서”로 합친 뒤 다른 군집보다 그 군집에서 두드러지는 단어의 가중치를 높인다.

단어 x 와 군집 c 의 가중치는 개념적으로 다음과 같이 쓸 수 있다.

$$w_{x,c} = \text{tf}_{x,c} \log \left(1 + \frac{A}{f_x} \right) \quad (11)$$

$\text{tf}_{x,c}$ 는 군집 c 에서 단어 x 의 정규화 빈도, f_x 는 모든 군집에 걸친 빈도, A 는 군집별 평균 단어 수에 기반한 값이다. 토픽 번호 자체에는 순서 의미가 없으며, `-1` 은 보통 HDBSCAN이 군집에 넣지 않은 잡음·이상 문서를 뜻한다.

16. 논문 도판 읽기: 품질과 계산비용





그림 1. Grootendorst (2022), “BERTopic,” Figure 1. Trump 데이터에서 어휘 크기를 늘리며 여러 토픽 모델의 벽시계 실행시간을 비교한다. 오른쪽은 매우 큰 CTM 값을 제외해 나머지 차이를 확대한다. [원문과 Figure 1](#)

가로축이 커질수록 어휘 크기가 증가하고, 세로축은 실행시간이다. 왼쪽에서 CTM-MPNET 곡선이 다른 방법보다 훨씬 크게 증가해 전체 축을 지배한다. 오른쪽 확대 그림은 그 곡선을 제외해야만 나머지 방법 사이 차이가 보인다는 점을 보여준다.

이 도판은 “가장 해석하기 좋은 주제”만 고르는 것이 충분하지 않음을 알려준다. 문서 수와 어휘가 증가할 때 임베딩 생성, UMAP, HDBSCAN, 대표어 계산의 시간·메모리를 각각 측정해야 한다.

17. Hands-On LLM 4장: 분류 전략 비교

교재의 분류 방법은 네 계열로 정리할 수 있다.

전략	레이블 데이터	장점	주의점
과업 특화 인코더 + 분류 헤드	필요	전체 미세 조정 가능	학습·배포 비용
임베딩 + 분류기	필요	빠른 실험, 모델 교체 쉬움	표현에 정보가 있어야 함
무예시 분류	불필요	빠른 시작	레이블 문구·임곤향 민감
생성형 분류	예시·지시문 선택	유연한 범주 설명	출력 파싱·비용·재현성

같은 분할과 매크로 F1, 혼동행렬을 사용해야 비교할 수 있다. 생성형 분류는 설명 문장을 출력할 수 있지만 정해진 범주 외 문자열, 형식 오류, 실행 비용을 평가에 포함해야 한다.

18. Hands-On LLM 5장: 토픽 결과 읽기

토픽 분석 결과는 다음 순서로 점검한다.

1. 군집 크기와 이상 문서 비율을 확인한다.
2. 상위 대표어와 대표 문서를 함께 읽는다.
3. 경계 문서와 잘못 묶인 문서를 찾는다.
4. UMAP·HDBSCAN 설정과 난수 시드를 바꿔 안정성을 측정한다.
5. 기존 범주, 시간, 출처와 군집의 관계를 교차표로 본다.
6. 사람이 붙인 주제 이름과 근거 문서를 기록한다.

LLM이 만든 주제 이름은 군집의 정답이 아니라 대표 문서에 대한 요약 가설이다. 이름과 맞지 않는 반례 문서를 함께 제시해야 한다.

19. Notebook 실행과 해석 점검

[week06.ipynb](#)은 창업·복지·관광 문서 각 세 개를 문자

2~4-그램 TF-IDF로 표현한다. 이 행렬은 사전학습 임베딩이 아니라 **희소 기준선**이다. 같은 분류·군집·축소 절차가 어떤 수치 특징에도 적용됨을 먼저 확인하는 미니 실험이다.

실행 전

1. “장애인 복지 이동 지원”이 어떤 문서와 가까울지 예측한다.
2. 어휘가 겹치는 창업·관광 문서가 혼동될 가능성을 적는다.
3. 표본이 범주별 세 개뿐이므로 결과의 불확실성이 큼을 기록한다.

실행 중

- `LeaveOneOut` 은 아홉 번에 걸쳐 한 사례씩 제외해 예측한다.
- 현재 Notebook은 `TfidfVectorizer` 를 전체 데이터에 먼저 맞추므로 교육용 단순화가 있다.
- 엄밀한 평가에서는 벡터화기와 분류기를 하나의 `Pipeline` 으로 묶어 각 학습 폴드 안에서만 맞춘다.
- k-means의 군집 번호 0, 1, 2는 정답 범주 번호가 아니다.

- 실루엣 계수와 ARI가 서로 다르면 어떤 공간 구조 때문에 그런지 문서를 읽는다.
- TruncatedSVD 그림의 축과 점 사이 빈 공간에 고유한 의미를 부여하지 않는다.

확장 실습

1. 범주별 문서를 10개 이상으로 늘리고 원문 ID 기반 그룹 분할을 만든다.
2. TF-IDF와 같은 분할에서 문장 임베딩 + 로지스틱 회귀를 비교한다.
3. PCA 또는 TruncatedSVD 두 차원의 설명 분산 비율을 기록한다.
4. 분류 실패 문서와 군집 경계 문서가 겹치는지 분석한다.
5. 난수 시드 5개에서 군집 지표의 평균과 표준편차를 보고한다.

20. 오류 분석과 모니터링

오류마다 입력 ID와 원문, 정답·예측, 가까운 학습 이웃, 가능한 원인, 서비스 피해, 수정 가설, 재실험 지표를 기록한다. “모델이 틀렸다”로 끝내지 않고 잘림, 중복, 어휘 편향, 레이블 모호성, 도메인 변화 같은 원인 범주로 코딩한다.

배포 뒤에는 다음 변화를 구분한다.

- 데이터 분포 변화(data drift): 길이, 언어, 주제 등 입력 분포 변화
- 개념 변화(concept drift): 같은 입력과 정답의 관계 변화
- 임베딩 공간 변화(embedding drift): 모델 버전 교체로 벡터 공간 자체 변화

벡터의 크기(L2 노름)와 언어·길이 분포, 군집 크기와 이상 문서 비율, 최근 레이블 성능, 모델 교체 전후 이웃 겹침률을 모니터링할 수 있다. 모델을 바꾸면 기존 색인과 군집 중심을 그대로 섞지 말고 다시 계산한다.

21. 최신 평가 관점

MTEB는 검색뿐 아니라 분류, 군집화, STS, 재순위화 등 여러 과업을 분리 평가한다. MMTEB는 평가 언어와 과업 범위를 크게 확장했다. 이 흐름이 주는 교훈은 “범용 평균 점수 1위”가 모든 분석에 최선은 아니라는 점이다.

실제 선택에서는 한국어 도메인 문서, 분석 단위, 입력 길이, 지연시간, 메모리, 라이선스를 먼저 고정한다. 분류에는 강하지만 군집 구조가 불안정한 모델도 있고 그 반대도 있을 수 있다.

22. 자주 하는 오해

1. 임베딩 그림에서 군집이 보이면 객관적 주제가 존재한다. 축소와 알고리즘이 만든 가설일 수 있다.
2. 선형 판독 모델이 높으면 모델이 그 개념을 이해한다. 정보가 선형적으로 읽힌다는 제한된 증거다.
3. 정확도가 높으면 불균형 문제도 해결됐다. 범주별 재현율과 매크로 F1을 확인해야 한다.
4. 군집 번호가 정답 범주와 대응한다. 번호에는 의미가 없고 대응은 평가 시 따로 찾는다.
5. 실루엣 계수가 높으면 유용한 주제다. 문체나 길이로 잘 분리된 것일 수 있다.
6. PCA·UMAP 축과 빈 공간은 원래 의미 거리다. 축소 과정에서 왜곡될 수 있다.
7. LLM이 붙인 토픽 이름이 정답이다. 대표 문서에 근거한 요약 가설이다.
8. 같은 문서의 청크를 무작위 분할해도 된다. 거의 동일한 정보가 분할 사이에 누수된다.

23. 핵심 정리

- 임베딩은 머신러닝 특징이며 데이터 분할·규제·기준선·오류 분석이 필요하다.
- 선형 판독 모델은 표현에서 정답 정보가 얼마나 쉽게 읽히는지 측정한다.
- k-NN은 국소 구조, 범주 대표 벡터는 레이블 설명과의 유사도를 이용한다.
- 군집은 거리와 알고리즘에 따른 분할 가설이며 내부·외부·안정성 평가를 함께 사용한다.
- PCA, t-SNE, UMAP 그림은 가설 생성용이며 원공간 지표로 다시 검증한다.
- BERTopic은 여러 모듈의 연쇄 파이프라인이므로 각 설정과 비용을 기록해야 한다.
- Notebook의 작은 TF-IDF 실험은 원리를 확인하는 기준선이며 실제 결론에는 더 큰 데이터가 필요하다.

24. 복습 문제

1. 같은 문서의 청크가 학습·최종 평가에 나뉘면 성능이 부풀려지는 이유를 설명하시오.
2. 선형 판독 모델의 성능이 측정하는 것과 측정하지 못하는 것을 각각 쓰시오.
3. k-NN에서 k 와 벡터 정규화가 결정 경계에 미치는 영향을 설명하시오.
4. 무예시 범주 대표 벡터 분류에 “기타” 범주가 필요한 사례를 제시하시오.
5. k-means 목적함수에서 중심이 각 군집의 평균이 되는 이유를 설명하시오.

6. 실루엣 계수와 ARI가 서로 다른 결과를 줄 수 있는 이유는 무엇인가?
7. TruncatedSVD와 중심화된 PCA의 차이를 Notebook 맥락에서 설명하시오.
8. UMAP 그림의 군집을 원공간에서 검증할 지표 세 가지를 제시하시오.
9. BERTopic 파이프라인에서 오류가 전파되는 경로를 한 가지 설명하시오.
10. 임베딩 모델 교체 시 다시 계산해야 할 산출물을 나열하시오.

참고문헌

1. Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning*, 2nd ed. [공개 PDF](#)
2. Rousseeuw, P. J. (1987). "Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis." [DOI](#)
3. van der Maaten, L. & Hinton, G. (2008). "Visualizing Data using t-SNE." [JMLR](#)
4. McInnes, L., Healy, J. & Melville, J. (2018). "UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction." [arXiv](#)
5. McInnes, L., Healy, J. & Astels, S. (2017). "hdbscan: Hierarchical Density Based Clustering." [JOSS](#)
6. Grootendorst, M. (2022). "BERTopic: Neural Topic Modeling with a Class-Based TF-IDF Procedure." [arXiv](#)
7. Muennighoff, N. et al. (2023). "MTEB: Massive Text Embedding Benchmark." [ACL Anthology](#)
8. Enevoldsen, K. et al. (2025). "MMTEB: Massive Multilingual Text Embedding Benchmark." [arXiv](#)
9. Hands-On LLM Authors. *Hands-On Large Language Models*, [Chapter 4](#) and [Chapter 5](#)