

07주차 · 임베딩과 검색 시스템 평가

- 연계 슬라이드: [../slides/week07_evaluation.md](https://slides/week07_evaluation.md)
- 실습 노트북: [../notebooks/week07.ipynb](https://notebooks/week07.ipynb)
- 교재 연계: *Hands-On Large Language Models*, Chapter 10의 임베딩 평가
- 권장 수업: 개념 45분 · 수학 35분 · 실습 70분 · 오류 분석과 토론 30분

1. 이번 주에 답할 질문

임베딩 모델의 순위표에서 점수가 가장 높은 모델을 고르면 평가가 끝나는가? 그렇지 않다.
평가 결과는 모델만의 고정된 속성이 아니라 다음 조건이 함께 만든 결과다.

$$R = R(M, D, T, \mu, S) \quad (1)$$

- M : 임베딩 모델과 추론 설정
- D : 평가 데이터와 그 분포
- T : 검색·분류·군집·의미 유사도 등의 과업
- μ : 평가 지표와 집계 방법
- S : 색인·재순위화·사용자 인터페이스까지 포함한 전체 시스템

예를 들어 영어 웹 문서의 의미 유사도에서 좋은 모델이 한국어 장학 규정 검색에서도
좋다고 보장할 수 없다. 모델 차원을 늘려 재현율이 1% 높아졌더라도 메모리 사용량과
지연시간이 네 배가 되면 실제 서비스에는 더 나쁜 선택일 수 있다. 이번 주의 목표는
“어느 모델이 좋은가?”를 “어떤 조건에서 어떤 증거로 더 낫다고 말할 수 있는가?”로 바꾸는 것이다.

2. 학습목표

학습을 마치면 다음을 할 수 있어야 한다.

1. 내재적 평가, 과업 평가, 전체 시스템 평가를 구분한다.
2. STS·분류·군집·검색 지표가 측정하는 대상을 설명한다.

3. P@k, R@k, MRR, DCG, nDCG를 작은 예제에서 직접 계산한다.
4. 과업 재현율과 ANN 재현율의 정답 집합이 다름을 설명한다.
5. MTEB와 MMTEB의 범위와 순위표의 한계를 판단한다.
6. 데이터 누수·평가 데이터 오염·불완전한 관련성 판정을 진단한다.
7. 품질·지연시간·메모리·비용을 함께 놓은 평가표를 작성한다.

3. 평가의 세 층

3.1 내재적 평가

내재적 평가(intrinsic evaluation)는 임베딩 표현 자체의 제한된 성질을 검사한다. 문장 쌍 유사도, 단어 유추, 가까운 이웃의 정성 분석 등이 여기에 속한다. 빠르고 원인을 관찰하기 쉽지만, 실제 사용자가 원하는 과업 성능을 직접 보장하지는 않는다.

예를 들어 “자동차-승용차”가 가깝고 “자동차-바나나”가 멀다는 사실은 합리적이다. 그러나 이 결과만으로 자동차 부품 검색에서 품번, 수치, 부정 표현을 정확히 처리한다고 결론 내릴 수는 없다.

3.2 과업 평가

과업 평가(task 또는 extrinsic evaluation)는 임베딩을 실제 과업에 넣어 측정한다.

- 분류: 임베딩 위에 단순 분류기를 학습하고 정확도·F1을 측정한다.
- 군집: 군집이 정답 범주 또는 데이터 구조와 얼마나 일치하는지 본다.
- 검색: 질의마다 관련 문서가 상단에 배치되는지 본다.
- 의미적 텍스트 유사도(STS): 사람의 유사도 순위와 모델 순위의 상관을 본다.

과업 평가에서는 임베딩 외의 조건을 고정해야 한다. 분류기의 복잡도, 데이터 분할, 정규화, 색인 설정이 다르면 모델 자체의 차이라고 해석하기 어렵다.

3.3 전체 시스템 평가

전체 시스템(system 또는 end-to-end evaluation)은 모델을 넘어 사용자가 받는 가치를 본다. 검색기, 근사 최근접 이웃 탐색(ANN) 색인, 재순위화 모델, 생성 모델, 화면과 권한 제어까지 포함한다. 품질뿐 아니라 지연시간, 메모리, 실패율, 비용, 안전도 측정 대상이다.

좋은 연구 질문은 다음처럼 조건을 명시한다.

한국어 정책 질의 100개에서 동일한 청크와 정확 탐색을 사용할 때, 모델 A는 TF-IDF 기준선보다 R@10을 높이며 그 차이의 95% 부트스트랩 신뢰구간이 0을 넘는가?

4. STS: 점수보다 순위를 비교한다

의미적 텍스트 유사도(Semantic Textual Similarity, STS)는 문장 쌍마다 사람이 부여한 유사도 y_i 와 임베딩 코사인 유사도 s_i 를 비교한다. 흔히 Spearman 순위 상관계수를 쓴다. 동순위가 없을 때의 직관적 공식은 다음과 같다.

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \tag{2}$$

d_i 는 두 순위에서 i 번째 문장 쌍이 차지한 순위의 차이이다. 예를 들어 사람 순위가 `[1, 2, 3, 4]`, 모델 순위가 `[1, 3, 2, 4]` 라면 $d = [0, -1, 1, 0]$ 이고,

$$\rho = 1 - \frac{6(0 + 1 + 1 + 0)}{4(4^2 - 1)} = 0.8 \tag{3}$$

이다. 절대 점수가 달라도 순서가 같으면 Spearman 상관은 높다. 실제 데이터에는 동순위가 있으므로 `scipy.stats.spearmanr` 처럼 동순위를 처리하는 구현을 사용한다. STS의 “의미가 비슷함”과 검색의 “질문에 답하는 문서임”은 다른 판단이라는 점도 중요하다.

5. 분류와 군집에서 무엇을 측정하는가

5.1 분류 지표

이진 분류에서 정밀도와 재현율은 다음과 같다.

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN} \tag{4}$$

F1은 두 값의 조화평균이다.

$$F1 = \frac{2PR}{P + R} \quad (5)$$

다중 범주에서는 평균 방법을 기록해야 한다. 매크로 F1은 범주별 F1을 같은 비중으로 평균하므로 소수 범주의 실패에 민감하다. 마이크로 F1은 모든 예측을 합쳐 계산하므로 큰 범주의 영향이 크다. 가중 F1은 범주별 표본 수를 가중치로 쓴다. 의로나 복지처럼 특정 범주의 누락 비용이 큰 경우에는 평균 하나보다 범주별 재현율을 먼저 확인한다.

5.2 군집 지표

정답 범주가 있다면 조정 랜드 지수(ARI), 정규화 상호정보량(NMI), V-measure를 사용할 수 있다. 정답 범주 없이 임베딩 공간의 구조만 본다면 실루엣 계수를 쓸 수 있다.

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (6)$$

$a(i)$ 는 표본 i 와 같은 군집 안 표본 사이의 평균 거리, $b(i)$ 는 가장 가까운 다른 군집과의 평균 거리다. 값이 1에 가까우면 잘 분리되고, 0 근처이면 경계에 있으며, 음수이면 다른 군집에 더 가까울 수 있다. 그러나 사람이 정한 범주가 실제 사용 목적을 잘 나타내지 못한다면 ARI가 낮다는 이유만으로 군집을 실패라고 부를 수 없다. 여러 난수 시드와 표본 재추출에서 군집이 안정적인지도 함께 본다.

6. 검색 평가 데이터의 구조

검색 평가에는 네 요소가 필요하다.

1. 질의 집합 Q
2. 검색 대상 말뭉치 D
3. 질의-문서 관련성 판정(qrels)
4. 검색기가 만든 순위 목록(run)

qrels는 이진형 또는 등급형일 수 있다. 이진형은 관련/무관만 구분하고, 등급형은 “매우 관련 3, 관련 2, 부분 관련 1, 무관 0”처럼 강도를 표현한다. 판정하지 않은 문서를 곧바로 무관하다고 간주하면, 기존 시스템이 찾지 못했던 새 관련 문서를 잘 찾는 모델이 오히려 불리해질 수 있다. 따라서 표본 판정이나 풀링을 통해 미판정 문서의 영향을 확인해야 한다.

7. 상위 k개 정밀도와 재현율

질의 q 의 관련 문서 집합을 R_q , 검색 결과 상위 k 개를 $\text{top}_k(q)$ 라 하자.

$$P@k = \frac{|\text{top}_k(q) \cap R_q|}{k} \quad (7)$$

$$R@k = \frac{|\text{top}_k(q) \cap R_q|}{|R_q|} \quad (8)$$

관련 문서가 A, C, E 세 개이고 상위 5개가 [A, B, D, C, F] 라면 관련 문서는 두 개다.

- $P@5 = 2/5 = 0.4$: 보여 준 다섯 개 중 40%가 관련 문서다.
- $R@5 = 2/3 \approx 0.667$: 가능한 관련 문서의 약 66.7%를 찾았다.

후보 생성 단계는 놓치면 뒤에서 복구할 수 없으므로 재현율을 중시한다. 사용자가 보는 최종 몇 개는 쓸모없는 결과를 줄여야 하므로 정밀도가 중요하다. k 보다 결과가 적을 때의 분모 처리와 관련 문서가 0개인 질의의 처리 규칙도 실험 전에 정해야 한다.

8. MRR: 첫 관련 문서까지의 대기

역순위(reciprocal rank, RR)는 첫 관련 문서의 순위만 사용한다.

$$\text{RR}(q) = \begin{cases} 1/r_q, & \text{첫 관련 문서가 순위 } r_q \text{에 있을 때} \\ 0, & \text{관련 문서를 찾지 못했을 때} \end{cases} \quad (9)$$

평균 역순위(mean reciprocal rank, MRR)는 질의별 RR의 평균이다.

$$\text{MRR} = \frac{1}{|Q|} \sum_{q \in Q} \text{RR}(q) \quad (10)$$

세 질의의 첫 관련 문서 순위가 1, 2, 없음이라면 MRR은

$(1 + 1/2 + 0)/3 = 0.5$ 다. 질의당 정답 하나를 빨리 보여 주는 질의응답이나 탐색 화면에는 적합하지만, 첫 정답 뒤의 관련 문서가 몇 개인지는 전혀 반영하지 않는다.

9. DCG와 nDCG: 등급과 위치를 함께 본다

할인 누적 이득(DCG)은 관련성이 높은 문서를 상단에 둘수록 큰 값을 준다.

$$DCG @k = \sum_{i=1}^k \frac{2^{rel_i} - 1}{\log_2(i + 1)} \quad (11)$$

슬라이드의 예 $[3, 0, 2]$ 를 계산하면

$$7 + \frac{0}{\log_2 3} + \frac{3}{\log_2 4} = 8.5 \quad (12)$$

이다. 이상적 순위 $[3, 2, 0]$ 의 IDCG는

$$7 + \frac{3}{\log_2 3} \approx 8.893 \quad (13)$$

이므로 $nDCG@3 = 8.5/8.893 \approx 0.956$ 이다. 정규화 할인 누적 이득(nDCG)은 질의마다 정답 수와 관련성 분포가 다를 때 0과 1 사이로 비교하기 쉽다. 단, 어떤 이득 함수와 로그 밑을 사용했는지 구현을 맞춰야 한다.

10. 과업 재현율과 ANN 재현율을 분리한다

근사 최근접 이웃 탐색의 재현율은 사람이 판정한 관련 문서가 아니라 정확 탐색 결과를 정답으로 삼는다.

$$ANNRecall @k = \frac{|NN_k^{approx} \cap NN_k^{exact}|}{k} \quad (14)$$

정확 탐색 상위 5개가 $[1, 2, 3, 4, 5]$, ANN 결과가 $[1, 2, 4, 7, 8]$ 이면 $ANNRecall@5$ 는 $3/5 = 0.6$ 이다. 그런데 문서 7과 8도 실제로 관련 있다면 과업 재현율은 높을 수 있다.

반대로 $ANNRecall@5$ 가 1이어도 임베딩 자체가 관련 문서를 상단에 두지 못하면 과업 성능은 낮다. 따라서 다음 순서로 진단한다.

1. 같은 임베딩으로 정확 탐색의 과업 지표를 측정한다.
2. ANN이 정확 탐색 이웃을 얼마나 재현하는지 측정한다.
3. ANN을 포함한 전체 과업 지표와 지연시간을 측정한다.

11. 논문 도판 읽기: MTEB




그림 1. MTEB가 평가하는 8개 임베딩 과업과 58개 데이터셋. 보라색은 다국어 데이터셋이다. 출처: Muennighoff et al. (2023), Figure 1, [ACL Anthology](#) 원문.

이 도판은 원의 크기보다 **평가 범위의 분기**를 먼저 읽어야 한다. 중심의 MTEB에서 분류·군집·쌍 분류·재순위화·검색·STS·요약 등 서로 다른 과업으로 가지가 뻗는다. 한 가지 평균 점수는 이 가지별 강점과 약점을 감춘다. 보라색 표시가 있더라도 모든 언어가 동일한 데이터 양과 난도를 갖는다는 뜻은 아니다. 우리 프로젝트가 검색이라면 전체 평균보다 검색 가지, 한국어 부분집합, 입력 길이가 비슷한 데이터셋을 우선 확인해야 한다.

원 MTEB의 중요한 결론은 모든 과업을 지배하는 단일 모델이 없었다는 점이다. MMTEB는 더 많은 언어와 과업으로 범위를 넓혔지만, 공개 벤치마크가 우리 조직의 문서·질의·오류 비용을 대신하지는 않는다.

12. 순위표를 읽는 일곱 가지 질문

1. 내 서비스와 같은 과업의 결과인가?
2. 한국어와 전문 용어가 포함되었는가?
3. 실제 입력과 최대 길이·질의/문서 형식이 같은가?
4. 모델별 지시문과 프롬프트 조건이 공정한가?
5. 모델 크기·차원·자료형·배치와 하드웨어는 무엇인가?

6. 학습 데이터에 평가 데이터가 포함되었을 가능성은 없는가?
7. 점수 차이가 통계적 변동과 운영 비용보다 충분히 큰가?

“1위”는 위 조건을 생략한 요약일 뿐이다. 모델 도입 보고서에는 모델명과 평균 점수 외에 버전, 풀링, 정규화, 차원, 입력 접두문, 라이브러리 버전도 남긴다.

13. 데이터 누수와 평가 데이터 오염

- 분할 누수: 같은 원문에서 나온 청크가 학습과 평가에 함께 들어간다.
- 시간 누수: 미래 문서의 정보가 과거 시점 예측에 사용된다.
- 중복 누수: 표현만 조금 다른 같은 문장이 양쪽에 들어간다.
- 설정 선택 누수: 최종 평가 데이터로 프롬프트나 혼합 가중치를 고른다.
- 평가 데이터 오염: 평가 항목 또는 가까운 변형을 모델이 학습해 기억한다.

문서 검색은 행 단위 무작위 분할보다 문서 ID나 기관 단위의 그룹 분할이 안전하다. 시간에 민감한 서비스는 특정 날짜 이전을 학습·개발 데이터, 이후를 최종 평가 데이터로 나눈다. 개발 데이터는 설정 선택에 사용할 수 있지만, 지나치게 반복해서 맞추면 개발 데이터에도 과적합할 수 있다. 이때는 교차 검증이나 새 개발 표본을 고려한다. 최종 평가 데이터는 설정을 고정한 뒤 한 번만 사용해야 한다.

14. 평균에는 불확실성을 붙인다

질의 20개에서 0.01점 차이가 났다고 해서 모델 A가 우수하다고 단정할 수 없다. 질의를 복원 추출하는 부트스트랩(bootstrap)으로 질의 집합의 변동성을 근사할 수 있다.

1. 질의 n 개를 복원 추출해 새 표본을 만든다.
2. 같은 표본에서 A와 B의 지표 차이 Δ_b 를 계산한다.
3. 이를 수천 번 반복한다.
4. Δ 분포의 2.5%와 97.5% 분위수를 95% 신뢰구간으로 보고한다.

두 모델은 반드시 같은 질의 표본에서 비교하는 짝지은 설계를 사용한다. 신뢰구간이 0을 포함하면 “차이를 확인하지 못했다”고 말하는 것이 적절하다. 통계적 유의성과 실제 서비스에 의미 있는 효과 크기는 별개의 문제다.

15. 품질 이외의 운영 지표

100만 개의 384차원 `float32` 벡터는 원시 벡터만 약 $1,000,000 \times 384 \times 4$ 바이트, 즉 약 1.43GiB가 필요하다. 1024차원이면 약 3.81GiB다. 색인의 그래프나 메타데이터는 여기에 추가된다.

평가 축	기록할 값의 예
품질	R@10, nDCG@10, 매크로 F1
인코딩	문서/초, 질의/초, p50·p95 지연시간
저장	벡터 차원, 자료형, 색인·디스크 크기
구축	색인 구축시간, 최대 RAM
비용	GPU 시간, API 비용, 전력
안정성	시간 초과, 오류율, 메모리 부족 비율

품질은 낮고 비용은 더 큰 후보는 다른 후보에 지배된다. 품질-비용 평면에서 지배되지 않는 후보들의 경계를 파레토 경계(Pareto frontier)라 한다. 임의의 가중 평균 하나를 만들기 전에 이 전선을 확인하고 서비스 제약에 맞는 지점을 선택한다.

16. 노트북 실습 안내와 점검 지점

[week07.ipynb](#) 는 외부 모델 없이 지표 계산을 검증하도록 구성되어 있다.

점검 1 · 준비 셀 실행 후

코사인 함수가 0벡터에서 0을 반환하는 이유를 설명한다. `SEED=42` 가 고정하는 것과 고정하지 못하는 것을 구분한다.

점검 2 · 지표 함수 셀 실행 전

다음 목록 `[1, 0, 1, 0, 0]` 에 대해 `P@3`, `R@3`(전체 관련 문서 3개), `RR`을 손으로 계산한다. 각각 $2/3$, $2/3$, 1이어야 한다. 그 뒤 함수 출력을 비교한다.

점검 3 · 세 검색기 결과표 생성 후

`per_query_results` 와 검색기별 평균을 함께 본다. 평균이 가장 높은 검색기가 모든 질의에서 이기는지 확인하고, 질의별 차이가 평균에서 어떻게 숨는지 한 문장으로 기록한다.

점검 4 · 실습 확장

질의 10개, 후보 문서 20개 이상으로 `qrels`를 만든다. 두 검색기의 결과를 `per_query_results.csv` 로 저장하고 가장 큰 실패 세 건에 대해 다음을 기록한다.

- 질의와 기대 문서
- 실제 순위와 지표
- 가능한 원인: 어휘 불일치, 부정, 수치, 긴 입력, 불완전 `qrels` 등
- 최소 수정 가설

생성형 AI를 사용했다면 프롬프트와 제안을 그대로 기록하되, 채택·수정·거부한 이유와 직접 실행해 확인한 증거를 덧붙인다.

17. 자주 하는 오해

- **오해:** 코사인 유사도가 높으면 정답이다.
교정: 유사도는 모델 공간의 가까움이며 과업 관련성 판정과 같지 않다.
- **오해:** MTEB 평균 1위면 어떤 서비스에도 최고다.
교정: 과업·언어·도메인·비용별 결과가 다르므로 자체 평가가 필요하다.
- **오해:** MRR과 nDCG는 비슷한 순위 지표이므로 아무거나 써도 된다.
교정: MRR은 첫 정답만, nDCG는 여러 문서의 등급과 위치를 반영한다.
- **오해:** ANN 재현율이 높으면 검색 품질도 높다.
교정: ANN 재현율은 정확 탐색 이웃의 재현이며 인간의 관련성 정답과 다르다.
- **오해:** 최종 평가 데이터를 여러 번 봐도 학습만 안 하면 괜찮다.
교정: 그 결과로 설정을 바꾸면 설정 선택 누수가 생긴다.
- **오해:** 평균 점수만 높으면 작은 집단의 실패는 중요하지 않다.

교정: 부분집합별 오류와 오류의 피해 규모를 함께 평가해야 한다.

18. 핵심 정리

1. 평가 결과는 모델·데이터·과업·지표·시스템의 결합이다.
2. 지표는 서로 다른 사용자 행동을 측정하므로 사용 시나리오에서 선택한다.
3. 검색 품질, ANN 근사 오차, 전체 시스템 품질을 분리해 측정한다.
4. 공개 벤치마크는 넓은 기준선이지 자체 한국어 최종 평가의 대체물이 아니다.
5. 평균에는 질의별 오류, 부분집합, 불확실성을 붙인다.
6. 품질과 지연시간·메모리·비용·안정성을 함께 비교한다.

19. 복습 문제

1. 평가 결과를 $R(M, D, T, \mu, S)$ 로 표현하는 이유를 실제 사례로 설명하라.
2. 관련 문서 4개 중 상위 5개에서 3개를 찾았다. P@5와 R@5를 계산하라.
3. 첫 관련 문서 순위가 [1, 4, 없음, 2] 일 때 MRR을 계산하라.
4. 등급 [2, 1, 0] 의 DCG@3을 계산하고 이상적 순위인지 판단하라.
5. 과업 R@10과 ANNRecall@10의 정답 집합은 각각 무엇인가?
6. 매크로 F1과 마이크로 F1이 크게 달라질 수 있는 데이터 예를 들어라.
7. 같은 정책 문서의 청크가 학습과 평가에 들어간 경우 어떤 누수이며 어떻게 막는가?
8. 모델 A의 nDCG는 높지만 p95 지연시간도 세 배라면 어떤 추가 정보로 결정할 것인가?

20. 참고문헌

1. Muennighoff, N. et al. (2023). "MTEB: Massive Text Embedding Benchmark." [EACL](#)
2. Lee, J. et al. (2025). "Massive Multilingual Text Embedding Benchmark." [arXiv](#)
3. Thakur, N. et al. (2021). "BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models." [NeurIPS](#)
4. Sakai, T. (2007). "On the Reliability of Information Retrieval Metrics Based on Graded Relevance."

Information Processing & Management

5. Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. [공개 교재](#)
6. Voorhees, E. M. (2001). "The Philosophy of Information Retrieval Evaluation." [Springer](#)
7. Efron, B., & Tibshirani, R. J. (1994). *An Introduction to the Bootstrap*. [CRC Press](#)
8. Alammam, J., & Grootendorst, M. (2024). *Hands-On Large Language Models*, Chapter 10. [공개 코드](#)