

WEEK 02 · TOKENIZATION & SPARSE VECTORS

토큰화가 세계를 자르고 희소 벡터가 단서를 센다

문자열 → 토큰 → 빈도 → TF-IDF/BM25 → 혼합 검색

오늘의 중심 주장

핵심

토큰화는 전처리가 아니라 모델이 볼 수 있는 최소 단위를 정하는 가설이다.

- “목포대학교”, “목포”, “대학교” 중 무엇이 한 단위인가?
- “신청하지 않았다”에서 부정은 유지되는가?
- 희귀한 학번·법령명·제품 코드는 밀집 임베딩보다 희소 검색에 유리할 수 있다.

학습목표

1. 토큰, vocabulary, OOV, 부분 단어, byte의 의미를 설명한다.
2. BPE·WordPiece·Unigram의 목표와 차이를 구분한다.
3. one-hot, BoW, TF-IDF, BM25를 직접 계산한다.
4. 희소·밀집 표현의 오류 양상을 비교하고 혼합 검색을 설계한다.
5. Hands-On LLM 2장의 토큰화기 비교 코드를 한국어 예제로 재현한다.

용어 지도: 문자열에서 ID까지

문자열(text) → 정규화(normalize) → 사전 분절(pre-tokenize) → 부분 단어 모델 → 정수 ID(encode)

토큰(token): 모델이 한 위치에서 처리하는 기호 단위.

어휘집(vocabulary): 토큰과 정수 ID의 유한한 대응표.

OOV(out-of-vocabulary): 어휘집에 없는 입력 단위.

토큰은 언어학적 "단어"와 같지 않으며, 토큰화기 버전도 모델의 일부다.

토큰화의 선택지

단위	장점	약점
단어/형태소	해석이 쉬움	신조어·복합어·형태 변이, 분석기 의존
문자	OOV가 거의 없음	시퀀스가 길고 의미 단위가 잘게 쪼개짐
부분 단어	길이·OOV의 절충	분절이 언어·데이터 빈도에 민감
byte	모든 문자열 표현 가능	토큰 수 증가, 사람이 읽기 어려움

주의

한국어: 조사·어미, 띄어쓰기 변이, 한글/영문/숫자 혼용 때문에 영어 토큰화기의 토큰 효율과 의미 보존이 그대로 유지되지 않는다.

BPE: 가장 빈번한 쌍을 합친다

간단한 학습 절차:

1. 단어를 문자(또는 byte) 단위로 시작한다.
2. 말뭉치에서 인접 기호 쌍의 빈도를 센다.
3. 가장 빈번한 쌍을 새 토큰으로 합친다.
4. 목표 어휘 크기까지 반복한다.

수식

학 생 들 → merge(학 , 생) → 학생 들 → merge(학생 , 들) → 학생들

- **BPE**는 결정적인 merge 규칙 목록을 배운다.
- 빈도가 높은 문자열은 긴 토큰, 희귀 문자열은 작은 조각으로 표현된다.
- 실제 구현은 공백 표식, 정규화, byte fallback 등 세부이 다르다.

WordPiece와 Unigram

WordPiece

후보 결합이 언어모델 우도 개선에 얼마나 기여하는지 고려하는 계열. BERT 토큰화기로 널리 알려짐.

예: `playing` → `play`, `##ing`

Unigram LM

큰 후보 어휘에서 시작해 우도를 덜 해치는 토큰을 제거. 한 문자열에 여러 분절 후보를 확률로 비교.

SentencePiece에서 사용 가능

참고: 이름만으로 구현을 단정하지 말고 토큰화기 설정 파일의 `normalizer`, `pre-토큰화기`, `모델`, `post-processor`를 확인한다.

토큰화 품질을 어떻게 측정할까

fertility	단어/문장당 생성 토큰 수
응답률	문자·도메인·언어를 손실 없이 표현하는가
downstream	검색·분류 성능과 비용이 어떻게 변하는가

추가 진단:

- 평균만 보지 말고 언어·길이·고유명사별 분포를 본다.
- 같은 문맥 창에서 토큰 수가 많으면 실제 답을 수 있는 내용이 줄어든다.
- [UNK], 잘림(truncation), 정규화 손실을 별도로 집계한다.

one-hot과 Bag of Words

어휘 크기 $|V|$ 가 5라면 토큰 하나의 one-hot은

$$\text{학 교} = [0, 1, 0, 0, 0]$$

문서 d 의 BoW 벡터는 각 토큰 빈도:

$$\mathbf{x}_d = [c(t_1, d), \dots, c(t_{|V|}, d)]$$

- 장점: 해석 가능, 정확한 키워드 보존, 빠른 inverted 색인
- 약점: 동의어 연결 부족, 어순·장거리 문맥 손실, 어휘가 클수록 고차원

정의

희소 벡터(희소 vector): 대부분 좌표가 0인 벡터. 실제 저장은 0이 아닌 색인과 값만 보관한다.

TF-IDF: 문서 안에서 중요하고, 말뭉치에서 드문 단어

한 가지 대표 정의:

$$\text{tfidf}(t, d) = \text{tf}(t, d) \times \log \frac{N + 1}{\text{df}(t) + 1}$$

기호	뜻
N	전체 문서 수
$\text{tf}(t, d)$	문서 d 안의 토큰 t 빈도
$\text{df}(t)$	토큰 t 가 등장한 문서 수

주의

라이브러리마다 log, smoothing, sublinear TF, L2 정규화가 다르다. “TF-IDF”라는 이름만 같

고 같은 다를 수 있다.

손계산: IDF가 하는 일

문서 4개 중

- 학교가 4개 문서에 등장: $\log((4 + 1)/(4 + 1)) = 0$
- 장학금이 1개 문서에 등장: $\log((4 + 1)/(1 + 1)) \approx 0.916$

공통어는 구분력이 낮고 희귀어는 구분력이 높다.

실습

토론: 희귀한 오타도 높은 IDF를 얻는다. 이것은 장점인가, 단점인가? 어떤 정규화/사전/최소 문서빈도로 제어할까?

BM25: 빈도 포화와 문서 길이 보정

$$\text{BM25}(q, d) = \sum_{t \in q} \text{IDF}(t) \frac{f(t, d)(k_1 + 1)}{f(t, d) + k_1(1 - b + b|d|/\text{avgdl})}$$

- 같은 단어를 100번 쓴다고 점수가 100배 되지 않는 **TF saturation**
- 긴 문서는 단어가 우연히 많이 등장하므로 **length 정규화**
- k_1 : 포화 속도, b : 길이 보정 강도

논문 읽기

BM25는 고전적이지만 여전히 강한 검색 기준선이다. 특히 ID·고유명사·희귀 키워드가 중요한 데이터에서 필요하다.

희소 vs 밀집: 서로 다른 실패를 한다

쿼리	희소 검색	밀집 검색
"근로장학 B-17 서식"	정확한 코드에 강함	코드가 희석될 수 있음
"등록금을 나눠 낼 수 있나요?"	"분할납부"와 어휘 gap	의미 대응 가능
"신청하지 않은 학생"	부정 토큰에 민감	부정을 놓칠 수 있음
최신 법령명	즉시 인덱싱 가능	학습 데이터에 없을 수 있음

핵심

둘 중 하나가 항상 우월한 것이 아니라 오류의 상관관계가 낮아 결합 가치가 크다.

희소·밀집 혼합 검색

점수 정규화 후 가중합:

$$s_{hybrid}(q, d) = \alpha \tilde{s}_{dense}(q, d) + (1 - \alpha) \tilde{s}_{sparse}(q, d)$$

또는 순위만 결합하는 역순위 융합(Reciprocal Rank Fusion, RRF):

$$\text{RRF}(d) = \sum_r \frac{1}{k + \text{rank}_r(d)}$$

- 서로 다른 점수 범위를 그대로 더하면 안 된다.
- α, k 는 개발 데이터 질의로 정한다.
- 메타데이터 필터는 결합 전/후 어느 단계에 적용하는지 기록한다.

Hands-On LLM 연결

토큰화기 비교에서 “토큰 수”와 “의미 손실”을 동시에 본다

원본 2장 실험을 한국어로 확장

```
texts = [
    "국립목포대학교 장학금 신청 안내",
    "AI·SW융합교육원 2026-2 프로그램",
    "신청하지 않은 학생은 제외합니다",
]

for name, tokenizer in tokenizers.items():
    ids = tokenizer(texts, add_special_tokens=False)["input_ids"]
    print(name, [len(x) for x in ids])
    print([tokenizer.convert_ids_to_tokens(x) for x in ids])
```

교재 연결

설명 포인트: 출력 토큰을 예쁘게 보여주는 데서 끝내지 말고, 모델별 평균 토큰 수·p95·숫자/영문/고유명사 분절을 표로 비교한다.

TF-IDF 기준선 코드 읽기

```
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.metrics.pairwise import cosine_similarity

vec = TfidfVectorizer(
    tokenizer=my_korean_tokenize,
    token_pattern=None,
    ngram_range=(1, 2),
    min_df=2,
    sublinear_tf=True,
)
X = vec.fit_transform(documents)           # [N, |V|], sparse
q = vec.transform([query])                 # [1, |V|]
scores = cosine_similarity(q, X)[0]
```

실습

텐서 모양 질문: $X.nnz / (X.shape[0] * X.shape[1])$ 은 무엇을 측정하는가?

최신 동향: 희소·밀집·multi-vector를 한 모델에


BGE-M3는 하나의 모델에서 세 검색 표현을 지원하도록 설계됐다.

- 밀집 — 문장/문서 단일 벡터
- 희소 — 학습된 어휘 가중치
- 다중 벡터 — 토큰 수준 후기 상호작용

논문 보고 범위: 100개 이상 언어, 최대 8,192 토큰 입력. 그러나 실제 선택은 자신의 한국어·도메인 평가로 결정한다.

출처: *Chen et al., "BGE M3-Embedding," Findings of ACL 2024* · [ACL Anthology](#) · [arXiv:2402.03216](#)

논문 도판: M3는 세 가지 “다중성”을 묶는다



실험 설계: 토큰화기 × 표현

같은 30개 문서·10개 쿼리에 대해 비교한다.

실험군	토큰화기	표현	측정
A	whitespace	TF-IDF unigram	재현율@5, vocab, sparsity
B	형태소/사용자 사전	TF-IDF 1-2gram	동일
C	모델 부분 단어	밀집 임베딩	재현율@5, 토큰 수, 시간
D	B + C	RRF 혼합	재현율@5, 오류 유형

주의

하이퍼파라미터를 최종 평가 데이터에서 고르면 평가 누수다. 학습/개발 데이터/최종 평가 역할을 구분한다.

수업 활동: 분절이 답을 바꾸는 순간

1. 팀마다 고유명사·부정·숫자·신조어가 포함된 한국어 문장 5개를 만든다.
2. 두 토큰화기의 토큰과 ID를 비교한다.
3. TF-IDF 상위 특성 10개를 확인한다.
4. “좋은 분절”을 토큰 모양이 아니라 검색 결과로 판정한다.

실습

제출 한 문장: “토큰화기 A는 ____ 때문에 토큰 수는 줄었지만/늘었지만, ____ 질의에서 재현율 @5가 ____했다.”

형성평가

1. 부분 단어가 OOV 문제를 완화하는 원리는?
2. TF-IDF에서 모든 문서에 등장하는 단어의 IDF는 왜 작아지는가?
3. BM25가 TF-IDF에 추가한 두 핵심 보정은?
4. 희소와 밀집 검색을 결합할 때 원점수 합이 위험한 이유는?
5. 토큰화기 비교에서 평균 토큰 수 외에 필요한 두 지표는?

교재 연결

Notebook: `../notebooks/week02.ipynb` · 토큰화기 결과와 희소 matrix를 모두 저장해 재현성을 확보한다.

핵심 정리

- 토큰화는 모델이 관측하는 단위와 계산 비용을 동시에 정한다.
- TF-IDF/BM25는 정확한 어휘 evidence를 보존하는 강한 기준선이다.
- 밀집 표현은 어휘 gap을 줄이지만 부정·코드·최신 고유명사를 놓칠 수 있다.
- 혼합는 두 오류 유형을 결합하되 개발 데이터으로 결합 규칙을 정한다.
- 최신 모델도 희소 표현을 버리기보다 통합하는 방향으로 발전한다.

핵심

다음 주: 단어의 의미를 주변 단어로부터 학습한다.

참고문헌과 원본 연결

- Sennrich et al. (2016), "Neural Machine Translation of Rare Words with Subword Units." [ACL Anthology](#)
- Kudo (2018), "Subword Regularization." [ACL Anthology](#)
- Robertson & Zaragoza (2009), "The Probabilistic **관련성** Framework: BM25 and Beyond." [DOI](#)
- Chen et al. (2024), "BGE M3-Embedding." [ACL Anthology](#)
- Hands-On Large Language Models, Chapter 2. [upstream](#)