

임베딩 기반 데이터 과학 · 06주차

WEEK 06 · EMBEDDING ANALYTICS

임베딩을 데이터로: 분류·군집·토픽 분석

벡터 생성은 분석의 끝이 아니라 feature engineering의 시작

국립목포대학교 컴퓨터학부 · Hands-On LLM 연계

오늘의 중심 질문

핵심

임베딩 공간에 구조가 “보인다”는 것과 **재현 가능한 분석 결과**는 어떻게 다른가?

- 시각화는 가설 생성 도구다.
- 분류/군집 지표는 정의한 label과 거리에 종속된다.
- 강한 baseline, split, 오류 분석이 없으면 점 구름은 증거가 아니다.

학습목표

1. 임베딩 행렬을 ML feature로 사용하는 파이프라인을 설명한다.
2. linear probe, k-NN, zero-shot prototype 분류를 비교한다.
3. k-means, hierarchical, DBSCAN/HDBSCAN의 가정을 구분한다.
4. PCA, t-SNE, UMAP 시각화를 과해석하지 않는다.
5. Hands-On LLM 4·5장의 분류와 BERTopic을 평가 가능한 분석으로 재구성한다.

분석 단위와 행렬을 먼저 고정한다

$$E \in \mathbb{R}^{n \times d}, \quad y \in \{1, \dots, C\}^n$$

체크할 것:

- 한 행은 문장, 문단, 문서, 사용자 중 무엇인가?
- 같은 원문에서 나온 여러 chunk가 train/test에 동시에 들어갔는가?
- 임베딩 모델이 test label/데이터로 이미 학습됐을 가능성은?
- normalize 전후 어떤 알고리즘을 쓰는가?
- missing/empty/truncated 문서는 어떻게 처리했는가?

주의

그룹 누수: 같은 문서의 chunk를 무작위 분할하면 거의 동일한 이웃이 train/test에 생겨 성능이 부풀려진다.

Linear probe

임베딩을 고정하고 단순 분류기만 학습한다.

$$P(y = c \mid z) = \text{softmax}(Wz + b)_c$$

- 표현 공간에서 label이 선형 분리되는지 측정
- 빠르고 해석 가능한 baseline
- 모델 전체 fine-tuning의 이득과 “표현 자체”의 품질을 구분
- regularization과 클래스 불균형 가중치 필요

정의

probe: 표현에 특정 정보가 얼마나 쉽게 읽히는지 측정하는 보조 모델. probe가 복잡할수록 표현과 probe 능력을 구분하기 어렵다.

k-NN 분류

새 점 z 의 최근접 학습 이웃 $N_k(z)$ 의 라벨로 결정:

$$\hat{y} = \arg \max_c \sum_{i \in N_k(z)} 1[y_i = c]$$

가중 투표:

$$\hat{y} = \arg \max_c \sum_{i \in N_k(z)} s(z, z_i) 1[y_i = c]$$

- 경계를 직접 학습하지 않고 공간의 국소 구조를 평가
- k , metric, 정규화, class density에 민감
- 큰 train set에서는 ANN index가 필요

Zero-shot prototype 분류

각 클래스 설명을 임베딩해 prototype으로 사용:

$$p_c = f_{\theta}(\text{“이 문서는 클래스 } c \text{에 관한 글”})$$

$$\hat{y} = \arg \max_c \cos(f_{\theta}(x), p_c)$$

- label data 없이 빠르게 시작 가능
- 클래스 이름의 다의성과 prompt 문구에 민감
- 여러 prompt를 평균하는 ensemble 가능
- threshold/“기타” 클래스 없으면 모든 입력을 억지로 분류

실습

비교: label name만, 정의문, 3개 예시를 넣은 prototype의 macro-F1을 비교한다.

분류 평가: accuracy만으로 부족하다

지표	질문	주의
accuracy	전체 중 맞은 비율	불균형 데이터에서 다수 클래스 지배
precision	예측 양성 중 실제 양성	false positive 비용
recall	실제 양성 중 찾은 비율	false negative 비용
macro-F1	클래스별 F1 평균	희귀 클래스 동일 가중
confusion matrix	어떤 클래스를 무엇과 혼동?	원인 분석의 시작

주의

threshold는 validation에서 결정하고 test에서는 고정한다. test를 보며 threshold를 조절하면 누수다.

k-means: 구형 군집 가정

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{z_i \in C_k} \|z_i - \mu_k\|_2^2$$

- K 를 미리 정해야 한다.
- 비슷한 크기·밀도의 볼록/구형 군집에 잘 맞는다.
- 초기화와 scale에 민감 → 여러 seed, k-means++
- L2-normalized 벡터의 cosine 구조에는 spherical k-means가 더 자연스러울 수 있다.

정의

cluster는 데이터에 “원래 있는 정답”이 아니라 알고리즘·거리·해상도가 만든 분할일 수 있다.

다른 군집 알고리즘

- **Hierarchical** — 병합/분할의 dendrogram. 거리와 linkage 선택이 핵심.
- **DBSCAN** — 밀도 기반, noise 허용. ϵ 과 min samples에 민감.
- **HDBSCAN** — 여러 밀도 수준의 안정적 군집을 찾고 noise를 분리.

논문 읽기

BERTopic은 기본적으로 UMAP으로 축소한 표현에 HDBSCAN을 적용한다. 군집 결과는 두 알고리즘의 하이퍼파라미터에 함께 종속된다.

군집 품질: 내부와 외부

종류	예	무엇을 비교하나
내부 지표	silhouette	같은 군집 응집도 vs 다른 군집 분리도
외부 지표	ARI, NMI, V-measure	정답 label과 군집 일치
안정성	seed/bootstrap overlap	데이터·초기화 변화에 결과가 유지되는가
사람 평가	coherence, usefulness	사람이 해석·활용 가능한가

주의

silhouette가 높아도 실제 주제와 무관한 길이·언어·문체로 분리됐을 수 있다. 군집별 대표/경계/이상 문서를 읽는다.

차원 축소 ① PCA

평균을 뺀 행렬 X 에서 분산이 큰 직교 방향을 찾는다.

$$\max_{\|w\|=1} \text{Var}(Xw)$$

- 선형, 빠름, transform을 새 데이터에 적용 가능
- explained variance ratio로 정보 압축 정도 확인
- 전역 선형 구조를 보존하지만 비선형 manifold는 제한적
- 2D 그림이 원래 d 차원 거리 전체를 보존하지 않는다.

차원축소 ② t-SNE와 UMAP

	t-SNE	UMAP
주 초점	국소 이웃 확률	국소 manifold의 fuzzy graph
전역 거리	매우 조심	상대적으로 낮지만 보장 아님
새 데이터 transform	구현/설정 의존	일반적으로 지원
민감도	perplexity, seed	neighbors, min_dist, metric, seed

주의

과해석 금지: 점 사이 빈 공간의 크기, 군집 면적, 축 방향을 원래 의미 거리로 직접 읽지 않는다.

BERTopic 파이프라인

문서 embedding → UMAP 축소 → HDBSCAN 군집 → c-TF-IDF 대표어 → topic label

정의

c-TF-IDF: 한 군집의 문서들을 하나의 “클래스 문서”로 합쳐, 그 군집에 특이적인 단어를 높게 만드는 표현.

토픽 번호는 의미가 없으며, **-1** 은 보통 noise/outlier다.

논문 도판: 품질뿐 아니라 계산비용도 비교한다

그림: Trump 데이터에서 vocabulary 크기를 늘리며 측정한 topic model별 wall time. 오른쪽은 큰 CTM 값을 제외해 나머지 차이를 확대한다.

교재 연결

Chapter 5의 embedding → UMAP → HDBSCAN → c-TF-IDF 파이프라인은 모듈별 품질뿐 아니라 **데이터 크기에 따른 실행시간**도 함께 평가해야 한다.

출처: Grootendorst (2022), "BERTopic," Figure 1 · [원 논문](#)

임베딩 기반 데이터 과학 · 06주차

Hands-On LLM 연결

4장 분류 + 5장 토픽 모델링을 하나의 분석 설계로 묶는다

국립목포대학교 컴퓨터학부 · Hands-On LLM 연계

Chapter 4: 네 분류 전략

전략	학습 데이터	비용/특징
task-specific model	필요	작은 encoder + 분류 head
embedding + classifier	필요	빠른 실험, 모델 교체 쉬움
zero-shot classifier	불필요	label/prompt 민감
generative classification	예시/지시	유연하지만 출력 파싱·비용 문제

교재 연결

강의 포인트: 같은 test split과 macro-F1/confusion matrix로 비교해야 전략의 trade-off가 보인다.

Embedding + logistic regression

```
Z_train = encoder.encode(x_train, normalize_embeddings=True)
Z_test  = encoder.encode(x_test,  normalize_embeddings=True)

clf = LogisticRegression(
    max_iter=2000,
    class_weight="balanced",
    random_state=42,
)
clf.fit(Z_train, y_train)
pred = clf.predict(Z_test)
```

반드시 TF-IDF + 같은 classifier 기준선과 비교한다. 데이터가 작을 때 고차원 임베딩은 regularization이 중요하다.

Chapter 5: 토픽 결과를 읽는 순서

1. topic size와 outlier 비율
2. top words와 representative documents
3. 경계 문서와 잘못 묶인 문서
4. seed/UMAP/HDBSCAN 변화에 대한 안정성
5. 기존 분류 label·시간·출처와의 관계
6. 사람이 붙인 topic name의 근거

주의

LLM이 생성한 토픽 이름은 군집의 “정답”이 아니라 요약 가설이다. 대표 문서 인용과 반례를 함께 제시한다.

오류 분석 표준 양식

필드	예시
입력 ID / 원문	<code>doc_017</code> , 실제 텍스트
정답 / 예측	장학 / 수강
top 이웃	어떤 train 문서가 영향을 줬나
가능한 원인	truncation, lexical overlap, label ambiguity
피해/비용	학생이 잘못된 절차를 따름
수정 가설	chunk 변경, hard negative, metadata
재실험	어떤 지표로 확인할까

실습

오류 5개를 “모델이 틀림”이 아닌 원인 category로 코딩하고 빈도를 집계한다. 더 큰 표본 분석은 선택 확장 활동으로 둔다.

Drift와 모니터링

시간이 지나면 입력·관계·라벨이 바뀐다.

- **data drift**: 입력 텍스트/언어/길이 분포 변화
- **concept drift**: 같은 입력과 정답의 관계 변화
- **embedding drift**: 모델/버전 변경으로 벡터 공간 자체 변화

모니터링 후보:

- norm·길이·언어별 분포, centroid 거리
- 최근 데이터의 분류 성능/검색 qrels
- cluster size/outlier 비율
- 모델 교체 전후 이웃 overlap@k

최신 동향: 한 표현, 여러 분석 과업

MTEB/MMTEB는 retrieval만이 아니라 classification, clustering, STS 등 다양한 과업을 분리 평가한다.

최신 동향

큰 모델이 모든 과업을 지배하지 않는다. 표현을 선택할 때 “범용 평균 점수”보다 실제 분석 과업·언어·길이·비용을 먼저 고정한다.

2025 MMTEB는 500개가 넘는 품질관리 과업과 250개가 넘는 언어로 평가 범위를 확장했다.

출처: Muennighoff et al. (2023), [MTEB](#) · Lee et al. (2025), [MMTEB](#)

수업 활동: 그림을 믿지 말고 검증하기

같은 임베딩 E 로 다음 네 그림을 만든다.

1. PCA 2D
2. t-SNE: 두 seed
3. UMAP: `n_neighbors=5`
4. UMAP: `n_neighbors=50`

그 다음 원래 d 차원에서 k-NN overlap, silhouette, 분류 macro-F1을 계산한다.

실습

보고: 2D에서 보이는 군집 중 원공간/label/seed 변화에도 유지되는 것과 사라지는 것을 구분한다.

형성평가

1. linear probe가 측정하려는 것은?
2. k-means가 암묵적으로 가정하는 군집 형태는?
3. UMAP 뒤 HDBSCAN을 쓰면 결과가 어떤 파라미터에 종속되는가?
4. 2D 축 사이 거리를 원래 의미 거리로 읽으면 안 되는 이유는?
5. 같은 문서의 chunk가 train/test에 섞이면 왜 누수인가?

교재 연결

Notebook: [../notebooks/week06.ipynb](#) · 분류 지표와 시각화 seed를 함께 기록한다.

핵심 정리

- 임베딩은 ML feature이며 split·baseline·regularization 규칙을 그대로 따른다.
- 분류 전략은 label 비용, 정확도, 지연시간으로 비교한다.
- 군집은 알고리즘과 metric이 만든 가설이며 안정성·사람 평가가 필요하다.
- 차원축소 그림은 가설 생성용이고 원공간 지표로 검증해야 한다.
- BERTopic은 embedding-UMAP-HDBSCAN-c-TF-IDF의 연쇄 파이프라인이다.

핵심

다음 주: “좋다”를 **재현 가능한 평가표**로 바꾼다.

참고문헌과 원본 연결

- van der Maaten & Hinton (2008), “Visualizing Data using t-SNE.” [JMLR](#)
- McInnes et al. (2018), “UMAP.” [arXiv](#)
- Grootendorst (2022), “BERTopic.” [arXiv](#)
- Muennighoff et al. (2023), “MTEB.” [ACL](#)
- Hands-On Large Language Models, [Chapter 4](#) · [Chapter 5](#)