

WEEK 07 · EVALUATION

임베딩의 "좋은"을 평가 설계로 증명하기

과업 → 데이터셋 → 지표 → 기준선 → uncertainty → 오류

점수 하나는 답이 아니다

핵심

평가 결과는 모델의 고유 속성이 아니라 모델 × 데이터 × 과업 × 지표 × 시스템의 함수다.

$$R = R(M, D, T, \mu, S)$$

- MTEB 평균 1등 ≠ 우리 한국어 장학규정 검색 1등
- 정밀도 1% 개선이 지연시간 10배를 정당화하는가?
- 평균은 어떤 언어·길이·집단의 실패를 숨기는가?

학습목표

1. intrinsic, extrinsic, downstream/system 평가를 구분한다.
2. STS·분류·군집·검색 지표를 계산하고 지표가 답하는 질문을 설명한다.
3. MTEB/MMTEB의 범위와 순위표 해석 한계를 설명한다.
4. 데이터 누수, 벤치마크 평가 데이터 오염, 불완전 qrels를 진단한다.
5. 정확도-지연시간-메모리-비용 Pareto 비교표를 만든다.

평가의 세 층

- **Intrinsic** — 유사도·analogy 등 표현 자체의 제한된 특성.
- **Task / Extrinsic** — 분류·군집·검색 등 실제 downstream 과업.
- **System** — 색인·재순위화 모델·LLM·UI를 포함한 전체 시스템 가치와 위험.

정의

좋은 연구 질문은 “모델 A가 좋은가?”가 아니라 “조건 C에서 지표 M과 비용 K로 볼 때 A가 기준선 B보다 나은가?”다.

STS: 순위 상관을 본다

문장 쌍별 정답 유사도 y_i 와 임베딩 cosine s_i 의 관계.

Spearman 순위 상관:

$$\rho = 1 - \frac{6 \sum_i d_i^2}{n(n^2 - 1)}$$

- 점수의 절대선형성보다 순위 일관성 평가
- tie가 있을 때는 일반적인 순위-correlation 구현 사용
- STS 레이블은 사람의 의미 유사성 판단이며 검색 관련성과 다를 수 있음

분류와 군집 지표

분류

- 매크로/마이크로/가중 F1 구분
- 불균형에서는 범주별 재현율
- calibration이 필요한 의사결정은 Brier/ECE 등 추가

군집

- ARI/NMI/V-measure: 레이블과 일치
- 실루엣 계수: 내부 거리 구조
- 안정성: 난수 시드/bootstrap/시간

주의

국립목포대학교 컴퓨터학과 Francisco Orjuela-Rico

외부 레이블과의 일치도가 낮다고 군집이 무조건 나쁜 것은 아니며, 레이블이 실제 사용 목적을

반영하는지도 검증한다

검색 평가 데이터의 구조

질의 $Q \rightarrow$ 말뭉치 $D \rightarrow$ 관련성 qrels $\rightarrow$ Run ranked lists $\rightarrow$ 지표

- binary qrels: relevant / not relevant
- graded qrels: 매우 관련/부분 관련/무관
- 관련 문서 하나인 데이터셋은 재현율@k가 단순하지만 실제 다중 정답을 놓칠 수 있음
- unjudged 문서를 “무관”으로 처리하면 새 모델이 불리할 수 있음

정밀도@k와 재현율@k

$$P@k = \frac{|\text{top}_k \cap R_q|}{k}$$
$$R@k = \frac{|\text{top}_k \cap R_q|}{|R_q|}$$

- 정밀도@k: 보여준 결과 중 얼마나 맞는가?
- 재현율@k: 가능한 정답 중 얼마나 놓치지 않았는가?
- 후보 생성 단계는 대개 재현율을, 최종 화면은 정밀도를 더 중시
- 정답 수가 질의마다 다르면 매크로 평균 해석에 주의

MRR: 첫 정답까지 얼마나 기다리는가

$$\text{RR}(q) = \frac{1}{\text{rank}_q^{(first\ relevant)}}$$

$$\text{MRR} = \frac{1}{|Q|} \sum_q \text{RR}(q)$$

첫 정답 순위	RR
1	1.0
2	0.5
5	0.2
없음	0

DCG와 nDCG: 순위와 등급을 함께

$$\text{DCG}@k = \sum_{i=1}^k \frac{2^{rel_i} - 1}{\log_2(i + 1)}$$

$$\text{nDCG}@k = \frac{\text{DCG}@k}{\text{IDCG}@k}$$

- 높은 관련성을 상단에 둘수록 큼
- ideal ranking으로 나눠 쿼리별 정답 수/등급 차이를 보정
- binary qrels에도 쓸 수 있지만 graded 관련성에서 특히 유용

실습

손계산: 관련성 $[3, 0, 2]$ 인 top-3의 DCG와 이상적 $[3, 2, 0]$ 의 nDCG를 계산한다.

ANN 평가: 검색 모델과 색인을 분리

두 종류의 재현율을 혼동하지 않는다.

- 과업 재현율@k — 정답 관련 문서를 찾았는가?
- ANN 재현율@k — 정확 탐색 상위 k개 이웃을 근사 색인이 얼마나 재현했는가?

$$\text{ANNRecall @}k = \frac{|NN_k^{approx} \cap NN_k^{exact}|}{k}$$

색인 파라미터를 바꾸면 임베딩 모델이 같아도 과업 성능과 지연시간이 달라진다.

MTEB가 바꾼 평가 관행

원 MTEB 논문은 다양한 임베딩을 한 틀에서 비교했다.

- 8개 과업 type
- 58개 데이터셋
- 112개 언어를 포함한 평가 범위
- 분류, 군집화, 쌍 분류, 재순위화, 검색, STS, summarization 등

핵심 결론: 모든 과업을 지배하는 단일 모델이 없었다.

출처: Muennighoff et al. (2023), "MTEB." · [EACL 2023](#) · [arXiv](#)

논문 도판: 하나의 평균이 여덟 과업을 숨긴다




그림: 원 MTEB의 8개 과업과 58개 데이터셋. 보라색은 다국어 데이터셋을 뜻한다.

MMTEB: 더 많은 언어와 과업

2025 연구 보고 범위:

- **500+** — 품질관리 평가 과업
- **250+** — 언어
- **다중 과업** — 검색뿐 아니라 다양한 임베딩 용도

논문에서는 560M 규모의 공개 모델이 더 큰 LLM보다 전체적으로 강한 사례도 보고했다. 크기만으로 선택할 수 없다는 증거다.

출처: Lee et al. (2025), "Massive Multilingual Text Embedding Benchmark." ·
[arXiv:2502.13595](https://arxiv.org/abs/2502.13595)

Leaderboard를 읽는 7문장

1. 내 과업과 같은 과업 subset인가?
2. 한국어와 내 도메인이 포함되는가?
3. 입력 길이와 질의/문서 형식이 같은가?
4. 지시문/프롬프트 조건이 공정한가?
5. 모델 크기·차원·dtype·배치가 무엇인가?
6. 공개/비공개 데이터와 평가 데이터 오염 가능성은?
7. 점수 차이가 변동성과 운영 비용보다 큰가?

주의

전체 평균은 서로 다른 데이터셋 scale과 중요도를 숨긴다. 먼저 목표 과업 subset과 per-데이터셋 결과를 본다.

데이터 누수와 평가 데이터 오염

위험	예	방지
분할 leakage	같은 문서 청크가 양쪽	문서/group 분할
시간 누수	미래 문서가 학습	time 분할
중복 누수	근사 중복 문장	hash/semantic dedup
벤치마크 학습	최종 평가를 학습 데이터로 사용	데이터 설명서, 비공개 유보 평가 데이터
설정 선택 누수	최종 평가로 프롬프트/alpha 선택	개발 데이터 고정

정의

평가 데이터 오염: 평가 항목 또는 가까운 변형이 사전학습/미세 조정 데이터에 들어가 일반화가 아닌 기억으로 점수가 오르는 현상.

통계적 불확실성

평균 점수만 보고 “A가 B보다 낫다”고 하지 않는다.

- 쿼리를 bootstrap resampling해 지표 차이의 신뢰구간 계산
- 같은 쿼리의 두 모델 결과를 짝지은 paired 비교
- 난수 시드가 필요한 학습/군집화는 여러 난수 시드 보고
- per-질의 차이 분포와 가장 크게 개선/악화된 사례 확인

```
delta = metric(model_a, sample_q) - metric(model_b, sample_q)
# bootstrap delta distribution → 2.5%, 97.5% quantiles
```

정확도 외 운영 지표

측	측정 예
품질	nDCG@10, 재현율@100, 매크로 F1
인코딩	docs/sec, 질의/sec, p50/p95 지연시간
저장	차원 × 자료형 × 말뭉치 크기
색인	build time, peak RAM, disk size
energy/비용	GPU-hour, API 비용, 전력 측정
안정성	timeout, 오류 rate, OOM 비율

최신 동향

Pareto frontier: 다른 후보보다 품질은 낮고 비용은 높은 모델은 제거한다. 단일 가중 평균을 만들거나, 또는 Pareto frontier를 찾아서 Pareto frontier에 바깥에 후보를 본다.

Hands-On LLM 연결

Chapter 10의 MTEB 평가를 우리 데이터셋의 실험표로 확장한다

최소 평가 프로토콜

1. 고정 최종 평가: 학기 초 qrels를 잠그고 변경 이력 관리
2. **Baselines**: BM25/TF-IDF, 작은 공개 임베딩
3. **Candidates**: 모델 2-3개, 동일 잘림 조건
4. 지표: 재현율@k + nDCG@10 + 지연시간 + 메모리 사용량
5. **Slices**: 한국어, 영숫자, 부정, 장문, 최신 문서
6. 오류: 최악 질의 20개를 원인 분류
7. 불확실성: bootstrap interval 또는 여러 난수 시드

교재 연결

재현성: 모델 이름만 쓰지 말고 모델 버전, 프롬프트, 정규화 여부, 차원, 라이브러리 버전을 결과 표에 포함한다.

모델 카드형 결과표

모델	dim	R@10	nDCG@10	p95 ms	1M fp32	비고
TF-IDF	\$	V	\$	—	—	—
Model A	384	—	—	—	1.43 GiB	한국어
Model B	1024	—	—	—	3.81 GiB	instruction
Model B-256	256	—	—	—	0.95 GiB	Matryoshka

실습

빈칸을 Notebook 측정값으로 채우고, 서비스 제약 안에서 선택한 모델과 버린 모델의 이유를 모두 쓴다.

수업 활동: 순위표 반박하기

팀별로 임의의 “1위 모델” 주장에 대해 반박 질문을 만든다.

- 어떤 데이터셋과 subset의 1위인가?
- 차이가 통계적으로/운영적으로 의미 있는가?
- 우리 데이터 부분집합에서 오류는?
- 비용과 라이선스는?
- 재현 가능한 설정이 공개됐는가?

실습

결과물: 모델 구매/도입 심의용 1페이지 평가 체크리스트.

형성평가

1. 재현율@k와 ANN 재현율@k의 분모/정답은 어떻게 다른가?
2. MRR이 첫 정답 이후를 무시하는 이유와 한계는?
3. nDCG가 graded 관련성에 적합한 이유는?
4. MTEB 평균 1등을 그대로 채택하면 안 되는 이유 세 가지는?
5. group 분할이 필요한 데이터 예를 하나 들어라.

교재 연결

Notebook: `../notebooks/week07.ipynb` · 지표를 직접 계산하고 모델별 질의 단위 차이를 저장한다.

핵심 정리

- 평가 질문이 먼저이고 모델 점수는 나중이다.
- 지표마다 보는 순위 행동이 다르므로 사용 시나리오와 연결한다.
- MTEB/MMTEB는 폭넓은 기준이지만 자체 한국어·도메인 최종 평가를 대체하지 않는다.
- 정확도와 함께 지연시간·메모리 사용량·비용·안정성을 측정한다.
- 평균 차이에는 불확실성과 오류 사례를 붙여야 한다.

핵심

다음 주: 평가한 벡터를 대규모 검색과 **RAG** 시스템에 배치한다.

참고문헌과 원본 연결

- Muennighoff et al. (2023), "MTEB." [EACL](#)
- Thakur et al. (2021), "BEIR." [NeurIPS Datasets and Benchmarks](#)
- Lee et al. (2025), "MMTEB." [arXiv](#)
- Sakai (2007), "On the Reliability of Information 검색 지표..." [DOI](#)
- Hands-On Large Language Models, Chapter 10. [upstream](#)