

WEEK 08 · VECTOR SEARCH & RAG

벡터에서 근거까지: 검색과 RAG 시스템

청크 → 임베딩 → 색인 → 검색 → 재순위화 → 생성 → 평가

RAG의 핵심은 생성보다 검색 계약이다

핵심

생성 모델이 답을 잘 쓰려면 먼저 정답 근거가 검색 가능한 단위로 존재해야 한다.

- 문서가 없으면 검색할 수 없다.
- 잘못 청크하면 정답과 조건이 분리된다.
- 상위 k개에 근거가 없으면 프롬프트 개선으로 복구하기 어렵다.
- 검색 성공과 근거 기반 답변 성공은 별도로 평가한다.

학습목표

1. 정확 k-NN과 ANN의 정확도-속도 상충 관계를 설명한다.
2. HNSW, IVF, PQ의 핵심 아이디어를 구분한다.
3. 문서 분할, 메타데이터, 희소·밀집 혼합, 재순위화 모델을 설계한다.
4. DPR/ColBERT/RAG의 표현과 정보 흐름을 비교한다.
5. Hands-On LLM 8장의 FAISS-재순위화-RAG 코드를 실패 단계별로 평가한다.

검색 시스템의 두 공간

- 원문 공간 — 텍스트, 표, 페이지, 날짜, 권한, 출처. 사람이 검증할 근거가 존재한다.
- 벡터 공간 — 검색을 위한 근사 표현. 원문의 모든 조건을 보존하지 않는다.

정의

색인(index): 질의마다 모든 벡터를 순차 비교하지 않고 후보를 빠르게 찾도록 만든 자료구조.

Exact k-NN vs Approximate NN

	정확 탐색	ANN 탐색
결과	정의한 지표의 정확한 상위 k개	높은 확률로 상위 k개 근사
비용	보통 말뭉치 크기에 선형	준선형보다 낮은 수준의 후보 탐색
용도	작은 말뭉치, 정답 기준	대규모 실서비스
평가	과업 지표	과업 지표 + ANN 재현율 + 지연시간

주의

ANN이 반환한 결과가 틀린 이유는 (a) 임베딩 순위 자체가 나뉘, (b) 색인이 정확 탐색의 이웃을 놓침으로 분해해야 한다.

HNSW: 가까운 길을 그래프로 찾는다

정의

Hierarchical Navigable Small World: 벡터를 근접 그래프에 연결하고, 희소한 상위 층에서 멀리 이동한 뒤 조밀한 하위 층에서 국소 탐색한다.

핵심 파라미터:

- **M** : 노드 연결 수 — 메모리/구축시간/재현율
- **efConstruction** : 구축 탐색 폭
- **efSearch** : 쿼리 탐색 폭 — 지연시간/재현율

논문 읽기

efSearch 를 늘리면 보통 재현율이 오르고 느려진다. 모델 교체 전 색인 파라미터 Pareto 곡선을 그린다.

IVF와 Product Quantization

- **IVF** — 벡터를 거친 군집 중심 목록으로 나누고 질의와 가까운 `nprobe` 개 목록만 검색.
- **PQ** — 벡터를 여러 부분 공간으로 나눠 각 부분을 짧은 코드로 양자화해 메모리와 거리 계산을 절약.
- IVF: `nlist`, `nprobe` 가 재현율-지연시간을 결정
- PQ: 코드 크기가 압축률-거리 왜곡을 결정
- 조합 예: `IndexIVFPQ`

출처: Johnson et al. (2017), *"Billion-scale similarity search with GPUs"* (FAISS)

문서 분할은 검색의 단위 설계

- 고정 길이 — 단순.빠름. 문장/표 경계를 자를 수 있음.
- 구조 기반 — 제목.문단.페이지.표 경계를 유지.
- 의미 기반 — 문장 간 변화로 분할. 비용.불안정성 증가.

겹침률은 경계 손실을 완화하지만 중복 후보.저장비용.근거 중복을 늘린다.

실습

평가: 청크 크기 128/256/512 토큰에 대해 정답 포함 재현율과 전체 지연시간을 비교한다.

좋은 청크의 조건

- 독립적으로 읽어도 주어·조건·날짜가 이해된다.
- 제목/문서명/시행일 같은 메타데이터와 연결된다.
- 정답 근거가 하나 또는 소수 청크에 완결된다.
- 인용할 때 원문 위치로 되돌아갈 수 있다.
- 변경된 문서만 다시 임베딩할 수 있도록 안정적인 ID가 있다.

주의

표의 한 행만 텍스트로 떼면 열 제목·단위가 사라진다. PDF/표 문서는 레이아웃 인식 문서 분할 또는 페이지 이미지 검색을 고려한다.

밀집 검색: DPR의 이중 인코더

$$s(q, p) = E_Q(q)^\top E_P(p)$$

질문 $q \rightarrow$ 질의 인코더 $\rightarrow z_q \rightarrow z_p$ 말뭉치 색인

- 문서 구절 벡터는 미리 계산
- 관련 문서 구절과 배치 내·혼동 비관련 예시로 학습
- 어휘 불일치에 강하지만 정확한 이름·수치·부정은 놓칠 수 있음

출처: Karpukhin et al. (2020), "*Dense Passage Retrieval*"

CoBERT: 후기 상호작용

쿼리 토큰 벡터 Q_i , 문서 토큰 벡터 D_j :

$$s(q, d) = \sum_i \max_j Q_i^\top D_j$$

- 이중 인코더 — 문서 1벡터, 가장 빠른 압축
- CoBERT — 토큰별 벡터를 사전 계산, MaxSim
- 교차 인코더 — 모든 토큰을 함께 계산, 가장 비쌘

출처: Khattab & Zaharia (2020), "[CoBERT](#)". 논문은 풍부한 상호작용을 유지하면서 교차 인코더보다 훨씬 빠른 검색을 목표로 한다.

혼합 후보 생성과 재순위화

BM25 상위 100개 → 밀집 검색 상위 100개 → RRF / 합집합 → 교차 인코더 상위 20개 → 문맥 상위 5개

- 1단계: 재현율 최적화
- 2단계: 정밀한 질의-문서 상호작용
- 생성 입력: 중복 제거, 문서 다양성, 토큰 예산 고려

주의

재순위화 모델이 후보에 없는 문서를 복구할 수는 없다. 후보 재현율과 재순위화 nDCG를 분리한다.

RAG의 정의

정의

검색 증강 생성(Retrieval-Augmented Generation, RAG): 모델 내부 지식과 외부 문서 색인을 결합해, 입력마다 근거 문서를 검색하고 그 조건에서 출력을 생성하는 방식.

원 논문의 두 변형:

- **RAG-Sequence**: 전체 출력 시퀀스에 같은 잠재 문서를 사용
- **RAG-Token**: 토큰마다 다른 잠재 문서 조합 가능

$$p(y \mid x) = \sum_{z \in \text{TopK}(x)} p_{\eta}(z \mid x) p_{\theta}(y \mid x, z)$$

출처: Lewis et al. (2020), *"Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks"*

논문 도판: 검색기와 생성기는 함께 학습된다




그림: 질의 인코더와 문서 색인이 상위 k 개 문서를 찾고, 생성기가 각 문서를 조건으로 출력 확률을 계산한다.

교재 연결

Chapter 8 실습은 이 구조를 문서 분할 → 임베딩 → FAISS 색인 → 검색 → 프롬프트 → 생성

논문 도판: 모델이 어떤 문서를 믿었나

Document 1: his works are considered classics of American literature ... His wartime experiences formed the basis for his novel **"A Farewell to Arms"** (1929) ...

Document 2: ... artists of the 1920s "Lost Generation" expatriate community. His debut novel, **"The Sun Also Rises"**, was published in 1926.




그림: RAG 논문의 문서 posterior 시각화. 생성 과정에서 검색 문서에 부여된 확률 질량을 분석한다.

출처: Lewis et al. (2020), RAG paper figure · [원문 HTML](#)

원 논문 수치에서 읽을 것

RAG 원 연구의 한 설정:

- 위키백과를 100단어 단위의 문서 구절 약 2,100만 개로 분할
- DPR 계열 검색기와 MIPS/FAISS 색인 사용
- 매개변수형 seq2seq 생성기 + 비매개변수형 색인 결합

논문 읽기

해석: 이 숫자는 오늘의 권장 청크 크기가 아니다. "지식 말뭉치를 검색 가능한 단위로 만들고 검색기와 생성기를 공동/연계한다"는 설계를 읽는다.

RAG 실패를 단계별로 분해한다

단계	실패	진단 지표
문서 수집·적재	최신 문서 없음/OCR 오류	응답률, 최신성
문서 분할	조건과 답 분리	정답 포함 재현율
검색	관련 청크 상위 k개 밖	재현율@k
재순위화	정답 후보를 아래로	재순위화 전후 nDCG/MRR
문맥	중복/잘림/순서	문맥 활용률
생성	근거 무시/왜곡	근거 충실성, 인용 정밀도

핵심

“RAG가 틀렸다”가 아니라 어느 단계에서 정답이 사라졌는가를 찾는다.

RAG 평가는 세 질문

- 검색 — 정답 근거가 상위 k개 안에 있는가?
- 근거 일치성(**grounding**) — 답의 주장과 인용이 제공 근거에 의해 지지되는가?
- 답변 정확성 — 질문을 정확하고 완전하게 해결했는가?
- LLM 평가자는 편리하지만 평가용 프롬프트.모델.버전과 사람 검증 표본이 필요
- 인용 존재 여부와 인용 정확성은 다르다.
- “모르겠습니다”를 허용하는 응답 보류 임계값을 평가한다.

보안: 검색 문서는 신뢰할 수 없는 입력

- 문서 안 프롬프트 주입: “이전 지시를 무시하라”
- 악성/오래된 문서의 색인 오염
- 권한 없는 문서가 벡터 검색으로 노출
- 개인정보가 임베딩·색인·로그에 잔존

주의

방어: 권한 필터를 검색 전에 강제, 출처 허용 목록/버전 관리, 문맥을 데이터로 구분, 인용 검증, 민감 정보 정책, 적대적 평가.

Hands-On LLM 연결

Chapter 8의 코드를 관찰 가능한 검색 파이프라인으로

Chapter 8 실행 흐름

```
chunks = chunk_documents(documents)
X = encoder.encode(chunks, normalize_embeddings=True)
index.add(X.astype("float32"))

q = encoder.encode([query], normalize_embeddings=True)
scores, ids = index.search(q.astype("float32"), k=20)
candidates = [chunks[i] for i in ids[0]]
reranked = reranker.rank(query, candidates)[:5]
answer = generator(query, reranked)
```

교재 연결

각 줄의 로그: 청크 ID/출처, 벡터의 크기(L2 노름)/차원, 1차 검색 원점수, 재순위화 점수, 최종 근거 문맥, 인용, 지연시간.

FAISS에서 자주 생기는 오류

- 코사인 유사도를 원하면서 정규화 없이 내적 색인 사용
- `float64` /object array를 넣어 타입 오류 또는 비효율
- 색인의 차원과 새 모델 출력 차원 불일치
- 모델을 교체하고 기존 색인을 재생성하지 않음
- 질의/문서 접두문을 다르게/빠뜨림
- ID 대응 관계를 잃어 원문·메타데이터로 돌아가지 못함

실습

단위 테스트: 자기 자신 검색, NumPy 정확 탐색과 FAISS의 상위 k개 일치, 저장-재로딩 후 ID/점수 일치.

최신 동향: 단일 텍스트 벡터 너머

- 혼합 표현 통합 — BGE-M3처럼 밀집·희소·다중 벡터를 함께 학습.
- 시각 문서 검색 — ColPali처럼 PDF 페이지 이미지를 직접 다중 벡터로 검색.
- 적응형 검색 — 질문 난이도에 따라 검색·재검색·도구 사용을 조절.

최신 동향

긴 문맥이 RAG를 없애는 것이 아니라 선택지를 바꾼다. 말뭉치 최신성, 권한, 인용, 비용을 관리해야 한다면 외부 검색은 여전히 중요하다.

출처: *BGE-M3 (2024)* · *ColPali (2024)*

수업 활동: 실패 위치 찾기

교수가 제공한 실패 질의 5개에 대해:

1. 정답 근거가 말뭉치에 있는가?
2. 어떤 청크에 들어갔는가?
3. 밀집/BM25/혼합의 순위는?
4. 재순위화 모델 전후 순위는?
5. 최종 문맥에 포함됐는가?
6. 생성기가 근거를 지켰는가?

실습

제출: 각 실패를 문서 수집·적재/청크/검색/재순위화/문맥/생성 중 하나 이상으로 분류하고 최소 수정안을 제시한다.

형성평가

1. HNSW의 `efSearch` 가 늘면 일반적으로 무엇이 변하는가?
2. PQ가 절약하는 자원과 잃을 수 있는 것은?
3. ColBERT와 bi-인코더의 문서당 벡터 수 차이는?
4. 재순위화 모델이 후보 재현율을 복구하지 못하는 이유는?
5. RAG의 검색, 근거 일치성, 답변 정확성 평가를 분리해야 하는 이유는?

교재 연결

Notebook: `../notebooks/week08.ipynb`

- 필수 실습: 200/500자 청크, TF-IDF/밀집 임베딩 검색, 근거 인용과 응답 보류 비교
- 선택 확장: 정확 탐색/ANN, 혼합 검색, 재순위화

핵심 정리

- 벡터 검색은 표현 모델과 ANN 색인의 결합이다.
- 문서 분할과 메타데이터가 검색 가능한 근거의 경계를 정한다.
- 혼합 검색과 재순위화는 서로 다른 오류를 줄이는 다단계 설계다.
- RAG는 검색과 생성을 결합하지만 실패는 단계별로 평가해야 한다.
- 보안·권한·출처·최신성은 정확도와 같은 1급 요구사항이다.

핵심

다음 주: 텍스트뿐 아니라 이미지와 문서 페이지도 같은 공간에 놓는다.

참고문헌과 원본 연결

- Karpukhin et al. (2020), "Dense Passage Retrieval." [arXiv](#)
- Khattab & Zaharia (2020), "ColBERT." [arXiv](#)
- Lewis et al. (2020), "Retrieval-Augmented Generation..." [arXiv](#)
- Johnson et al. (2017), "Billion-scale similarity search with GPUs." [arXiv](#)
- Faysse et al. (2024), "ColPali." [arXiv](#)
- Hands-On Large Language Models, Chapter 8. [upstream](#)