

텍스트와 이미지를 같은 의미 공간에 정렬하기

dual encoder → contrastive alignment → visual document retrieval → omni-modal

다른 센서, 공유할 수 있는 의미

- **텍스트** — “푸른 바다 위를 항해하는 흰 배”
- **이미지** — 픽셀 배열 속 바다·배·색·구도

정의

멀티모달 임베딩: 서로 다른 양식(modality)의 입력을 비교 가능한 공동 공간 또는 정렬된 표현으로 매핑하는 학습된 표현.

목표: 대응 image-text는 가깝게, 비대응 쌍은 멀게.

학습목표

1. modality, alignment, fusion, shared embedding space를 설명한다.
2. CLIP의 dual encoder와 symmetric contrastive loss를 설명한다.
3. zero-shot 분류와 cross-modal retrieval의 prompt 의존성을 분석한다.
4. OCR 기반 문서 검색과 visual document embedding을 비교한다.
5. Hands-On LLM 9장의 멀티모달 입력을 검색/생성 관점으로 분리한다.

멀티모달 설계의 세 방식

- **Dual encoder** — 각 modality를 독립 encode 후 공동 공간에서 비교. 대규모 검색에 유리.
- **Fusion encoder** — 토큰/패치를 함께 attention. 세밀하지만 모든 쌍 계산이 비쌘.
- **Late interaction** — 각자 사전 계산한 다중 벡터를 query 시점에 세밀하게 매칭.

텍스트 검색의 bi-/cross-/ColBERT 구분과 구조적으로 대응한다.

이미지를 토큰처럼: patch representation

Vision Transformer의 기본 직관:

1. 이미지를 $P \times P$ patch로 나눈다.
2. 각 patch를 펼쳐 선형 투영한다.
3. position 정보를 더한다.
4. Transformer가 patch 관계를 문맥화한다.

$$N = \frac{HW}{P^2}, \quad X_{patch} \in \mathbb{R}^{N \times d}$$

주의

작은 글자·표·세밀한 도형은 image resolution과 patch size 때문에 손실될 수 있다.

CLIP: 대조적 언어-이미지 사전학습

배치 N 개의 image-text pair에서 $N \times N$ 유사도 행렬을 만든다.

$$S_{ij} = \frac{\hat{I}_i^\top \hat{T}_j}{\tau}$$

대각선 ($i = i$)을 정답으로 image→text와 text→image cross-entropy를 평균한다.

$$\mathcal{L} = \frac{1}{2}(\mathcal{L}_{I \rightarrow T} + \mathcal{L}_{T \rightarrow I})$$

논문 읽기

원 연구는 웹에서 수집한 4억 image-text pair로 학습하고 30개가 넘는 vision dataset에서 zero-shot transfer를 연구했다.

출처: Radford et al. (2021), [“Learning Transferable Visual Models From Natural Language Supervision”](#)

논문 핵심 도판: CLIP의 세 단계

그림: (1) image-text 대조 사전학습 → (2) label 문장으로 분류기 생성 → (3) zero-shot 예측.

교재 연결

Chapter 9의 CLIP 코드는 image embedding과 text embedding을 직접 비교하고, prompt 문구가 zero-shot classifier의 결정경계를 어떻게 바꾸는지 실험한다.

출처: Radford et al. (2021), Figure 1 · [원문 HTML](#)

Figure 1 읽기

- **1. Pre-train** — 대각선 pair 점수는 높게, 나머지는 낮게.
- **2. Text classifier** — A photo of a {label} 을 encode해 클래스 weight로.
- **3. Predict** — 새 image embedding과 class text embedding의 cosine 비교.

정의

분류 head를 label data로 다시 학습하지 않고 자연어 label 설명으로 동적으로 구성하는 것이 zero-shot transfer의 핵심이다.

Prompt가 곧 클래스 정의다

단순 label 배 는 fruit/boat/stomach 중 모호하다.

배

바다 위를 항해하는 배의 사진

먹을 수 있는 한국 배 과일의 사진

- class name만 쓰지 말고 문맥 template을 사용
- 여러 template embedding을 평균해 ensemble
- 한국어/영어 prompt의 pretraining 분포 차이 평가
- class가 폐쇄집합인지, “해당 없음” 처리가 있는지 확인

Cross-modal retrieval

방향	query	corpus	예
text→image	문장	image embeddings	“빨간 안전모를 쓴 작업자”
image→text	이미지	captions/docs	사진 설명·상품 찾기
image→image	이미지	images	유사 디자인/제품
text→page	질문	PDF page images	표·도표가 있는 규정 페이지

평가: Recall@k, median rank, nDCG, 언어/객체/텍스트 포함 여부별 slice.

OCR-first 문서 검색

PDF page → OCR/layout → text chunks → text embedding → retrieve

장점:

- 텍스트를 직접 인용·검색·필터링 가능
- 기존 text RAG 인프라 재사용

약점:

- 표 셀 관계, 도식, 글자 위치가 선형 텍스트에서 손실
- OCR 오류가 후속 모든 단계에 전파

Visual document retrieval

페이지 이미지를 vision-language encoder로 직접 표현:

page image → **patch multi-vectors** → **query token multi-vectors** → **late interaction**

- 원래 layout·표·그림·font 단서를 보존
- page당 다중 벡터라 저장·검색 비용 증가
- 찾은 페이지에서 정확한 답을 추출하는 별도 단계 필요

논문 도판: ColPali의 token-patch 유사도

그림: 텍스트 *query token*이 문서 페이지의 어떤 시각 영역과 높은 *late-interaction* 점수를 만드는지 보여주는 *similarity map*.

출처: Faysse et al. (2024), “ColPali,” *similarity map* · [원 논문](#)

국립목포대학교 컴퓨터학부 · Hands-On LLM 연계

ColPali가 바꾼 질문

기존 질문: “OCR을 얼마나 잘해서 텍스트로 바꿀까?”

새 질문: “페이지 시각 구조를 그대로 보존해 검색할 수 있을까?”

- PaliGemma 계열 VLM으로 페이지를 patch-level multi-vector로 표현
- ColBERT식 late interaction으로 query token과 page patch 매칭
- 시각적으로 풍부한 문서 검색을 위한 ViDoRe benchmark 제시

주의

similarity map은 모델 내부 점수 시각화다. 정답 근거의 인과적 증명이나 OCR 정확도를 대신하지 않는다.

임베딩 기반 데이터 과학 · 09주차

Hands-On LLM 연결

Chapter 9의 VLM을 표현·검색·생성으로 분해한다

국립목포대학교 컴퓨터학부 · Hands-On LLM 연계

멀티모달 LLM 입력 흐름

이미지 → Vision encoder → visual tokens → text tokens → LLM generation

교재 연결

구분: VLM이 이미지를 설명하는 생성 능력과, corpus 전체를 빠르게 검색하는 embedding 능력은 같은 평가 문제가 아니다.

확인할 tensor/조건:

- image resolution/resize/crop
- image token 또는 patch 수
- text-vision projector
- 최대 context와 여러 이미지 처리
- chat template와 special token

생성 데모를 평가로 바꾸기

```
prompt = "이 이미지의 표에서 2026년 예산을 근거와 함께 답하라."  
output = vlm.generate(image, prompt)
```

필요한 평가:

- OCR 정확도: 숫자·단위·한글
- grounding: 답이 실제 표 셀/영역에 있는가?
- hallucination: 보이지 않는 내용을 만들었는가?
- robustness: resize, crop, 회전, 압축에 견디는가?
- latency/memory: text-only 대비 비용

최신 동향 ① 범용 멀티모달 임베딩

연구	방향	발표 상태
jina-embeddings-v4	text+image, single/multi-vector, task LoRA	2025 preprint
Qwen3-VL-Embedding	text/image/mixed input, 긴 문맥·Matryoshka	2026 preprint
Gemini Embedding 2	text/image/audio/video 공동 공간	2026 preprint
jina-v5-omni	text/image/audio/video, GELATO	2026 preprint

출처: [Jina v4](#) · [Qwen3-VL-Embedding](#) · [Gemini Embedding 2](#) · [Jina v5 omni](#)

최신 동향 ② “한 벡터”에서 선택 가능한 표현으로

- **Single vector** — 빠른 1차 검색
- **Multi-vector** — 토큰-패치 정밀 매칭
- **Matryoshka** — 차원별 비용 조절

최신 동향

모델 하나가 여러 모달리티·과업·granularity를 지원하는 방향이지만, index 복잡도·adapter 선택·평가 범위가 함께 커진다.

멀티모달 편향과 안전

- 웹 image-text pair의 문화·언어·성별·직업 연관 편향
- 얼굴/사람 검색의 프라이버시와 오인식 피해
- OCR에 포함된 개인정보·문서 권한 유출
- prompt에 따라 class definition이 이동
- adversarial image/text가 공동 공간을 교란

주의

배포 전: 얼굴/민감 속성 용도 제한, 집단별 평가, consent와 retention, access control, human review를 요구사항으로 둔다.

수업 활동: OCR vs visual embedding

같은 PDF 페이지 20장과 질문 10개로 비교:

방식	표현	측정
A	OCR text + text embedding	Recall@5, OCR error
B	page image + visual embedding	Recall@5, latency/storage
C	A+B hybrid	Recall@5, 오류 보완

페이지 유형별 slice: 본문 / 표 / 차트 / 스캔 / 2단 편집.

실습

결론: 평균뿐 아니라 어떤 layout에서 어느 방식이 이기는지 오류 지도를 작성한다.

형성평가

1. CLIP의 $N \times N$ 행렬에서 positive는 어디인가?
2. zero-shot 분류에서 text prompt가 하는 역할은?
3. dual encoder와 fusion encoder의 검색 비용 차이는?
4. OCR-first와 page-image 검색의 정보 손실이 각각 무엇인가?
5. ColPali가 single-vector CLIP 검색과 다른 점은?

교재 연결

Notebook: [../notebooks/week09.ipynb](#) · image/text similarity와 prompt 변화를 기록한다.

핵심 정리

- 멀티모달 임베딩은 서로 다른 입력을 비교 가능한 공간에 정렬한다.
- CLIP은 batch 대조학습과 자연어 클래스 설명으로 zero-shot transfer를 가능하게 했다.
- prompt는 멀티모달 분류의 동적 클래스 정의다.
- 문서 검색은 OCR text와 visual layout 중 무엇을 보존할지 선택한다.
- 최신 방향은 single/multi-vector, Matryoshka, omni-modal을 한 모델에 통합한다.

핵심

다음 주: 모든 선택을 **하나의 재현 가능한 프로젝트**로 통합한다.

참고문헌과 원본 연결

- Radford et al. (2021), “CLIP.” [arXiv](#)
- Dosovitskiy et al. (2021), “An Image is Worth 16x16 Words.” [ICLR](#)
- Faysse et al. (2024), “ColPali.” [arXiv](#)
- Lähn et al. (2025), “jina-embeddings-v4.” [arXiv](#)
- Qwen Team (2026), “Qwen3-VL-Embedding.” [arXiv](#)
- Hands-On Large Language Models, Chapter 9. [upstream](#)