

WEEK 10 · CAPSTONE & TRENDS

좋은 임베딩 실험을 좋은 데이터 서비스로

요구사항 → 기준선 → 모델 → 색인 → 평가 → 배포

종합 프로젝트의 중심 주장

핵심

최신 모델을 쓴 프로젝트보다 의사결정의 근거가 추적되는 프로젝트가 강하다.

- 왜 이 표현을 선택했는가?
- 어떤 기준선보다 얼마나 나아졌는가?
- 어디서 실패하며 누구에게 피해가 가는가?
- 같은 커밋과 설정으로 재현되는가?

학습목표

1. 데이터-표현-검색/분석-서비스를 전체 시스템으로 설계한다.
2. 기능 요구사항을 측정 가능한 품질·비용·안전 지표로 바꾼다.
3. 기준선, 요소 제거 실험, 오류 분석이 포함된 실험계획을 작성한다.
4. 2013-2026 임베딩 기술 흐름을 문제 해결 방식의 변화로 설명한다.
5. 최종 보고서·데모·구술평가에서 자신의 기술 선택을 방어한다.

문제 정의 캔버스

항목	반드시 답할 질문
사용자	누가 언제 어떤 결정을 하는가?
입력	텍스트/이미지/문서의 언어·길이·권한은?
출력	순위, 분류, 군집, 답변 중 무엇인가?
정답	관련성/레이블을 누가 어떻게 정의하는가?
오류비용	FP와 FN 중 무엇이 더 위험한가?
제약	p95 지연시간, RAM, 비용, 라이선스, 개인정보

정의

“AI로 문서를 검색한다”는 문제 정의가 아니다. 사용자 행동과 성공 지표까지 써야 한다.

종단 간 참조 구조

출처 버전 관리 → 파싱·청크 → 임베딩·색인 → 검색·재순위화 → UI/API 피드백

횡단 관심사:

- 평가 데이터셋과 실험 추적
- 접근 제어, 개인정보 보호, 출처 표시
- 모니터링, 롤백, 모델/색인 버전 관리

기준선 사다리

- 0 — 규칙/빈도/무작위
- 1 — TF-IDF/BM25 + 고전 ML
- 2 — 기성 임베딩 모델
- 3 — 혼합/재순위화/미세 조정

논문 읽기

각 단계가 이전 단계를 얼마나 개선하고 어떤 비용을 추가했는지 표로 남긴다. 복잡한 모델이 기준선을 못 이기면 데이터·과업 정의부터 점검한다.

모델 선택표

기준	질문	후보 기록
과업	검색/STS/분류?	학습 목표
언어·도메인	한국어·전문용어를 평가했나?	부분집합별 점수
길이	실제 p95 토큰을 수용하나?	잘림 비율
표현	밀집/희소/다중 벡터?	색인 방식
비용	차원, 매개변수 수, 처리량?	p95 지연시간/RAM
운영	라이선스, 오프라인 실행, 모델 버전?	모델 카드

데이터셋을 제품 요구사항에서 만든다

1. 실제 사용자 질문 유형을 표본 추출한다.
2. 중복·개인정보·권한을 처리한다.
3. 관련성 채점 기준과 주석자 교육 자료를 만든다.
4. 다중 정답과 등급형 관련성을 허용한다.
5. 언어·길이·부정·숫자·최신성 부분집합을 태깅한다.
6. 문서/시간 단위 분할로 누수를 막는다.
7. 최종 평가 데이터를 잠그고 버전을 부여한다.

주의

공개 벤치마크를 재현하는 것과 제품을 평가하는 것은 별도 목표다. 둘을 함께 보고하면 전이 격차를 설명할 수 있다.

요소 제거 실험: 무엇이 실제로 기여했나

실험	바꾸는 것	고정할 것
청크	128/256/512	모델/색인/qrels
표현 방식	BM25/밀집/혼합	청크/최종 평가 질의
차원	64/256/전체	모델/프롬프트/색인 계열
재순위화 모델	끔/کم	후보 상위 k개
프롬프트	지시문 A/B	근거/모델/디코딩

정의

요소 제거 실험(ablation study): 시스템 구성요소 하나를 제거·변경해 성능 변화로 그 기여를 추정하는 통제 실험.

오류 분석은 다음 실험을 만든다

실패 수집 → 원인 부호화 → 빈도·피해 → 수정 가설 → 재평가

권장 오류 분류체계:

- OOV/고유명사, 부정·수치, 잘림, 다국어
- 불완전 레이블/qrels, 모호한 질의
- ANN 누락, 메타데이터 필터, 재순위화 모델의 순위 역전
- 근거 누락, 인용 불일치, 근거 없는 생성(환각)

재현성 패키지

```
project/
├── README.md           # 실행·평가 순서
├── configs/            # 모델/색인/체크/prompt
├── 데이터/README.md    # 출처·스키마·분할·라이선스
├── src/                # 재사용 가능한 코드
├── notebooks/          # 탐색·오류 분석
├── 평가/               # qrels, metrics, frozen runs
└── reports/            # 결과표, 모델/데이터 카드
```

기록: Git 커밋, 패키지 잠금 파일, 난수 시드, 모델 버전, 하드웨어, 실행시간.

데이터 카드와 모델 카드

- 데이터 카드(data card) — 출처·수집·동의·필터·언어·결측·분할·알려진 편향·허용 용도.
- 모델/시스템 카드 — 학습목표·입출력·지표·부분집합·비용·한계·금지 용도·모니터링.

주의

카드는 홍보 문서가 아니라 다음 사용자가 오용하지 않게 하는 운영 인터페이스다.

배포: 모델과 색인은 한 버전 단위

벡터 공간이 달라지면 기존 색인을 재사용할 수 없다.

```
embedding_model_revision + 토큰화기 + 풀링 + normalize  
+ dimension + chunker_version + corpus_snapshot + index_config  
= index_version
```

- 블루/그린 색인으로 교체와 롤백
- 신규 문서의 증분 갱신과 삭제 전파
- 질의 로그의 개인정보 최소화
- 품질/지연/오류율 대시보드와 경보

성능 예산

구간	p50/p95	throughput	비용
질의 인코딩	—	q/s	GPU/API
ANN retrieve	—	q/s	RAM/CPU
재순위화	—	pairs/s	GPU
생성	—	토큰/s	GPU/API
전체 시스템	—	req/s	전체

최신 동향

성능 최적화 순서: 측정 → 병목 식별 → 배치/cache/차원/색인 조정 → 품질 회귀 테스트. 품질을 모른 채 지연시간만 줄이지 않는다.

2013–2026: 문제 해결 방식의 변화

시기	대표 흐름	핵심 변화
2013–2017	Word2Vec, GloVe, fastText	단어 분포를 정적 벡터로
2017–2019	Transformer, BERT, SBERT	문맥화와 문장 단위 비교
2020–2022	DPR, CoBERT, RAG, CLIP, MRL	검색·생성·멀티모달·가변 차원
2023–2024	MTEB, BGE-M3, ColPali	통합 평가, 혼합/multi-vector, 시각 문서
2025–2026	Qwen3/Jina/Gemini 계열	instruction, 다국어, 옴니모달, 유연한 표현

논문 읽기

연도표는 “이전 기술이 사라졌다”는 뜻이 아니다. 새 표현은 비용·데이터·평가 문제를 추가한다.

최신 기술 동향 ① 통합

- 과업 통합 — 임베딩 + 재순위화 + 생성을 지시문으로 통합.
- 표현 통합 — 밀집 + 희소 + 다중 벡터를 하나의 기반 모델에서 처리.
- 양식 통합 — 텍스트 + 이미지 + 오디오 + 비디오를 공동 공간에 배치.

최신 동향

통합 모델은 운영 단순화를 약속하지만, 각 양식의 최적 프롬프트·어댑터·색인·지표를 여전히 따로 검증해야 한다.

논문 도판: 임베딩과 재순위화의 역할은 다르다




그림: Qwen3-Embedding은 입력별 독립 벡터를 만들고, Qwen3-Reranker는 질의-문서를 함께 보고 관련성 점수를 출력한다.

교재 연결

국립목포대학교 컴퓨터학부 Hands-On LLM 연계

Chapter 8의 1차 검색과 재순위화, Chapter 10의 임베딩 학습을 한 시스템으로 묶되 후보 재현

유기 재저력 포지은 보기 평가한다

최신 기술 동향 ② 효율

- Matryoshka 표현의 차원 축소
- 곱 양자화, 이진/int8 임베딩
- 거친 단계에서 정밀 단계로 이어지는 단일→다중 벡터 검색
- 지식 증류와 작은 인코더의 경쟁력
- 합성 질의·비관련 예시로 데이터 효율 개선
- 장문 인코딩과 적응형 문서 분할

출처: *Matryoshka Representation Learning · BGE-M3 · Qwen3 Embedding*

최신 기술 동향 ③ 평가의 확대

MTEB → MMTEB의 흐름은 “평균 점수”가 아니라 평가 범위를 확장한다.

- 더 많은 언어와 문자 체계
- 검색 이외의 임베딩 과업
- 지시문·프롬프트의 공정한 처리
- 모델 크기·공개성·비용 비교
- 평가 데이터 오염과 데이터 품질 점검

주의

2026년 사전 공개 논문의 주장과 순위표 순위는 변할 수 있다. 학기 시작일에 버전·날짜를 표시하고 자체 고정 최종 평가 데이터를 우선한다.

윤리·법·안전 게이트

배포 전 “예/아니오”로 확인:

- 데이터 수집·재사용·모델 라이선스가 허용되는가?
- 개인/민감 정보가 임베딩, 로그, 캐시에 남는가?
- 사용자 권한이 검색 전에 강제되는가?
- 집단별 오류와 가장 큰 피해를 측정했는가?
- 근거와 모델 한계를 UI에서 고지하는가?
- 삭제·정정·이의제기·롤백 경로가 있는가?

Hands-On LLM 종합 연결

2·3·4·5·8·9·10장의 예제를 하나의 증거 사슬로

책의 장을 프로젝트 단계에 매핑

프로젝트 단계	Hands-On LLM	질문
표현 이해	Ch.2-3	토큰/은닉 상태/풀링은 무엇인가?
분석	Ch.4-5	분류·군집 결과를 어떻게 검증하나?
검색·RAG	Ch.8	청크-색인-재순위화 중 병목은?
멀티모달	Ch.9	OCR/텍스트와 이미지 representation 중 무엇을 보존?
미세 조정	Ch.10	데이터-손실함수-평가기가 같은 관련성을 정의하나?

교재 연결

원칙: 책 코드를 그대로 실행한 화면은 산출물이 아니다. 우리 데이터, 기준선, 지표, failure case 를 추가해야 한다.

최종 프로젝트 필수 산출물

1. 문제정의서와 사용자 시나리오
2. 데이터 카드와 고정 평가 세트
3. 실행 가능한 코드/Notebook/설정
4. 기준선 1개와 임베딩 방법 1개의 비교표
5. 개발에서 수행한 개선 실험 1개
6. 서로 다른 실패 사례 5개와 원인 분석
7. 최종 평가 품질 지표와 질의·예제별 결과
8. 안전·라이선스·개인정보 검토
9. 10분 발표·시연과 5분 질의응답

선택 확장: 두 번째 임베딩 모델, 복수 요소 제거 실험, 신뢰구간, 지연시간·메모리 사용량·비용 분

석은 가산점 없는 심화 활동이다.

구술평가 질문 은행

- 왜 cosine이며 inner product/L2가 아닌가?
- normalize를 제거하면 순위가 어떻게 바뀌는가?
- 최종 평가 누수를 어떤 분할로 막았는가?
- BM25가 이긴 질의의 공통점은?
- 가장 큰 실패 유형과 피해는?
- 색인 파라미터를 바꾸면 모델 점수와 어떻게 분리해 평가하는가?
- 새 문서/삭제/권한 변경은 어떻게 반영되는가?
- 예산이 절반이면 무엇을 줄이고 무엇을 지킬 것인가?

최종 발표 구조: 10분

시간	내용
0:00-1:00	사용자, 입력, 출력과 위험한 오류
1:00-3:00	데이터, 정답, 분할과 기준선
3:00-5:00	임베딩 방법과 선택 근거
5:00-7:00	최종 평가 결과와 개선 실험 1개
7:00-8:00	실패 사례와 한계
8:00-10:00	새 입력 시연과 다음 단계

실습

모델 이름보다 선택 근거와 실패 분석에 더 많은 시간을 배분한다.

제출 전 체크리스트

재현	증거
빈 환경에서 처음부터 실행	기준선을 같은 조건으로 비교
난수 시드·모델 버전·설정 고정	최종 평가를 tuning에 사용하지 않음
데이터 경로와 라이선스 기록	오류 원문과 문서 ID 보존
결과표 자동 생성	품질·비용·안전을 함께 보고

주의

Notebook 출력만 있고 실행 순서·환경·데이터 출처가 없으면 재현 가능한 제출로 보지 않는다.

과정 전체 핵심 정리

1. 임베딩은 과업에 필요한 관계를 공간에 보존하는 함수다.
2. 토큰화·풀링·정규화가 결과를 바꾼다.
3. 학습목표의 positive/negative가 “가까움”을 정의한다.
4. 분석 그림은 원공간 지표와 오류 사례로 검증한다.
5. 검색은 청크-representation-색인-재순위화의 시스템이다.
6. 최신 모델도 기준선·자체 데이터·비용 평가를 대체하지 않는다.

핵심

좋은 임베딩이란 우리의 의사결정을 더 정확하고 책임 있게 만드는 표현이다.

참고문헌과 최신 동향 원문

- Vaswani et al. (2017), "Attention Is All You Need." [arXiv](#)
- Reimers & Gurevych (2019), "Sentence-BERT." [arXiv](#)
- Lewis et al. (2020), "RAG." [arXiv](#)
- Muennighoff et al. (2023), "MTEB." [ACL](#)
- Lee et al. (2025), "MMTEB." [arXiv](#)
- Zhang et al. (2025), "Qwen3 Embedding." [arXiv](#)
- Gemini Embedding 2 (2026 preprint). [arXiv](#)
- Hands-On Large Language Models. [upstream](#)